

1. Summary

Dieses Papier ordnet ML, KI und GenAI¹ im Energiesektor nicht als Tool-Upgrade, sondern Wegbereiter eines neuen Betriebsmodells für datengetriebene kritische Infrastruktur. Im Mittelpunkt stehen On-/Offshore-Windenergie, der zugehörige Netzbetrieb sowie Battery Energy Storage Systems (BESS) als Kopplungsglied zwischen Erzeugungsvolatilität, Netzrestriktionen und Marktlogik. Die zentrale These lautet: Der Wert von KI entsteht sowohl durch robuste algorithmische Verfahren als auch durch die Fähigkeit, aus Daten operativ belastbare Evidenz zu machen – unter Unsicherheit, Zeitkritik und komplexen Nebenbedingungen.

Viele KI-Anwendungen im Energiesektor senken primär die Kosten der Vorhersage: Forecasts, Ausfallwahrscheinlichkeiten, Zustandsindikatoren werden schneller und oft präziser. Wert entsteht jedoch erst, wenn diese Evidenz in verantwortete Entscheidungen und Maßnahmen übersetzt wird – unter Netzsicherheits-, Safety-, Haftungs- und Degradationsrestriktionen. Deshalb lohnt eine klare Trennung: Prediction Tasks liefern probabilistische Information; Decision Tasks optimieren Zielfunktionen unter Nebenbedingungen. Dazwischen liegen die eigentlichen Komplementärinvestitionen: Datenintegration, Kontextmodellierung, MLOps/LLMOps, OT-Security sowie Prozess- und Rollenklärung.

Das Papier strukturiert die Diskussion entlang dreier Wirkprinzipien: (i) *Wahrnehmung* (z. B. Anomalieerkennung, Musteranalyse, Vision AI), (ii) *Vorausschau* (probabilistische Prognosen, Restlebensdauer- und Degradationsmodelle, simulationsgestützte Risikoabschätzung) und (iii) *Entscheidungsvorbereitung* (robuste Optimierung, sichere Exploration, Dispatch- und Einsatzplanung). Gleichzeitig wird herausgearbeitet, warum „experimentelle Data Science“ häufig dort scheitert, wo betriebsfähige KI beginnen muss: in Prozessen, Rollen, IT/OT-Architektur, MLOps/LLMOps, Sicherheitslogik und Auditierbarkeit. Wenn diese Fähigkeiten mit Werkzeugen und betrieblichen Workflows verbunden werden, kommt eine weitere Frage hinzu: Wie lässt sich operative Autorität schrittweise erweitern, ohne Verantwortlichkeit, Eingriffsrechte und technische Sicherheitsgrenzen zu verwischen?

Ein Schwerpunkt liegt deshalb auf der Betriebs- und Governance-Perspektive: Zielsysteme sind im Energiesektor mehrdimensional; Proxy-KPIs können Fehlanreize erzeugen; OT-Cybersecurity ist Voraussetzung für Skalierung; und GenAI benötigt Provenienz, Observability und SLOs, um produktiv und verantwortbar zu werden. Auf dieser Basis werden exemplarische Use Cases beschrieben, von Ertrags- und Einspeiseprognosen über Predictive Maintenance, Wake-Steering und Offshore-O&M-Optimierung bis hin zu netznaher Ereigniskorrelation, Engpass-/Schalthandlungs-unterstützung, OT-Cybersecurity, GenAI in der Wissensarbeit sowie BESS-spezifischen Steuerungs- und Wertstapelungslogiken.

2. Einordnung und strategischer Hintergrund

Generative KI ist im Energiesektor nicht nur eine Frage neuer Werkzeuge, sondern eine strategische Infrastrukturentscheidung. Wer GenAI produktiv einsetzt, entscheidet implizit über Abhängigkeiten entlang einer Kette aus Rechenkapazität (GPU/HPC), Datenzugang, Modellanbieter, Sicherheits- und Governance-Fähigkeit sowie Talent. Besonders im europäischen Kontext ist relevant, dass sowohl Daten als auch skalierbare Rechenressourcen, Referenzanwendungen, Kapital und rechtssichere Vertrauensräume zu Engpässen werden können. Daraus ergibt sich eine zweigleisige Adoptionslogik: Kurzfristig kann man im „Windschatten“ etablierter Modelle schnelle Produktivitäts-gewinne heben, etwa in Engineering-Wissensarbeit, Dokumentation, Analyse-Assistenz oder Modellierungsworkflows. Mittel- bis langfristig wird jedoch entscheidend, eigene Handlungsfähigkeit aufzubauen: durch souveräne Datenräume, klar definierte Betriebsumgebungen, kontrollierte Modellnutzung, und dort, wo es strategisch sinnvoll ist, durch eigene Modelle oder zumindest eigene Inferenz-Stacks. Gerade für kritische Infrastruktur gilt: Time-to-Value darf nicht zu unreflektiertem Lock-in führen. Ein GenAI-Programm sollte deshalb von Beginn an „Reversibility by Design“ verfolgen: Modelle, Daten und Inferenz-Stacks sind derart zu gestalten, dass Anbieter wechselbar bleiben, nicht erst als nachträgliche Compliance-Schleife.

Der Einsatz von Machine Learning, Künstlicher Intelligenz und generativer KI in der Windenergie und im Netzbetrieb ist somit kein Selbstzweck und auch keine Modeerscheinung, sondern Ausdruck einer strukturellen Veränderung des Energiesystems. Mit dem Ausbau der Onshore- und Offshore-Windenergie steigt die Volatilität im Erzeugungsportfolio, während gleichzeitig die Anforderungen an Verfügbarkeit, Prognosegüte, Netzstabilität, Betriebsführung und regulatorische Nachweisfähigkeit wachsen. Hinzu kommt, dass viele Assets – insbesondere offshore – schwer zugänglich, kapitalintensiv, wartungsaufwendig und über

Jahrzehnte zu betreiben sind. In einem solchen Umfeld entsteht der Wert von KI nicht dadurch, dass menschliche Expertise ersetzt wird, sondern dadurch, dass Daten, Modelle und Entscheidungslogiken so kombiniert werden, dass Zustände früher erkannt, Risiken robuster bewertet und Maßnahmen konsistenter vorbereitet werden können.

Die eigentliche Relevanz von KI liegt damit an der Schnittstelle von Unsicherheit, Zeitkritik und Komplexität. Windparks und Netze sind keine statischen technischen Objekte, sondern dynamische Systeme mit stochastischen Einflüssen, partiell beobachtbaren Zuständen, gekoppelten Nebenbedingungen und häufig widersprüchlichen Zielgrößen. Ein Offshore-Windpark muss gleichzeitig hohe technische Verfügbarkeit, wirtschaftlichen Ertrag, sichere Zugänglichkeit, logistische Beherrschbarkeit und netzkonforme Einspeisung gewährleisten. Der Netzbetrieb muss Versorgungssicherheit, N-1-Fähigkeit, Spannungs- und Frequenzhaltung, Cyber-Resilienz, regulatorische Konformität und Wirtschaftlichkeit parallel sicherstellen. In beiden Welten ist deshalb nicht die Frage entscheidend, ob Daten vorhanden sind, sondern ob aus Daten entscheidungsfähige Information wird.

Vor diesem Hintergrund lassen sich drei grundlegende Wirkprinzipien unterscheiden. Erstens verbessert KI die Wahrnehmung des Systems, etwa durch Anomalieerkennung, Musteranalyse oder bildbasierte Inspektion. Zweitens verbessert sie die Vorausschau, etwa durch probabilistische Ertrags- und Lastprognosen, Restlebensdauermodelle oder simulationsgestützte Risikoabschätzung. Drittens verbessert sie die Vorbereitung von Entscheidungen, indem sie aus Prognosen, Restriktionen und Zielsystemen belastbare Vorschläge für Instandhaltung, Dispatch, Schalthandlungen oder Einsatzplanung ableitet. Genau an dieser dritten Stelle trennt sich allerdings experimentelle Data Science von betriebsfähiger KI: Im industriellen Betrieb genügt es nicht, dass ein Modell statistisch gut ist; es muss

¹ GenAI (Generative Artificial Intelligence) bezeichnet KI-Modelle (meist Large Language Models), die aus gelernten Mustern neue Inhalte wie Text, Code, Bilder oder strukturierte Antworten erzeugen und dafür häufig durch Retrieval (RAG) mit geprüften Quellen „geerdet“ werden

in Prozesse, Rollen, IT/OT-Architekturen, Sicherheitsregeln, Verantwortlichkeiten und Eskalationsketten eingebettet sein.

Deshalb sollte das Thema nicht als isolierte Technologieinitiative verstanden werden, sondern als Teil eines neuen Betriebsmodells für datengetriebene kritische Infrastrukturen. Die entscheidende Governance-Frage lautet: Welches Ziel wird eigentlich optimiert? Viele KI-Projekte scheitern nicht an fehlender Modellleistung, sondern an einer unsauberen Zielfunktion. Wenn etwa Curtailment reduziert, O&M-Kosten gesenkt oder Verfügbarkeitskennzahlen verbessert werden sollen, kann dies zu Fehlanreizen führen, sofern Sicherheitsreserven, Lebensdauerverhalten, Systemstärke, Personalbelastung oder Fairnessaspekte nicht mitmodelliert werden. Im Energiesystem ist deshalb die Differenz zwischen dem eigentlichen Ziel und dem messbaren Proxy besonders relevant. Gute KI im Wind- und Netzbetrieb ist daher immer mehrzielig, restriktionssensitiv und auditierbar.

Diese Wirkprinzipien beschreiben, wie operative Intelligenz entsteht. Predictive AI schätzt künftige Zustände und Unsicherheit. Numerische Optimierung bewertet zulässige Handlungsoptionen unter definierten Nebenbedingungen. GenAI erschließt und strukturiert unstrukturierte Information. Agentische Koordination verbindet diese Fähigkeiten mit Kontext, Werkzeugen, Freigaben und operativer Weiterverarbeitung. Deterministische Automatisierung bleibt dort angemessen, wo sich erforderliche Aktionen zuverlässig über validierte Regeln und Steuerungslogiken festlegen lassen.

Diese Fähigkeiten bilden einen Betriebsstack und keine Abfolge von Reifestufen. Ein Forecasting Modell kann analytisch hochentwickelt sein und dennoch nur geringe operative Autorität besitzen. Umgekehrt kann eine einfache deterministische Aktion hohe betriebliche Konsequenz haben. Auswahl der Fähigkeit und Gestaltung der Autorität sollten deshalb aus Entscheidungsbedarf, Evidenzqualität, Reversibilität und physischer Fehlerfolge abgeleitet werden.

3. Architektur- und Betriebslogik

3.1 Systemgrenzen und hybride Architektur

Eine tragfähige industrielle KI Architektur beginnt mit einer klaren Abgrenzung des betrachteten Betriebssystems. Das kann ein Windpark, ein BESS Portfolio, eine Konverterstation, ein Instandhaltungsprozess oder ein Netzbetriebsworkflow sein. Die Systemgrenze bestimmt, welche Daten, Entscheidungen, Restriktionen und Schnittstellen dazugehören und an welcher Stelle Verantwortung auf einen anderen Owner oder eine andere Betriebsdomäne übergeht. Auf dieser Grundlage lassen sich Architektur, Integration und operative Autorität sinnvoll gestalten. Eine weitere Grundannahme dieses Kompendiums ist, dass KI im industriellen Umfeld fast nie als reine Cloud-Lösung funktioniert. Die reale Architektur ist in der Regel hybrid. Zentrale Plattformen eignen sich für Flottenanalytik, Trainingspipelines, Portfoliomodellierung, probabilistische Prognosen und langfristige Optimierung. Edge-nahe Systeme sind dort erforderlich, wo Latenz, Datenhoheit, Kommunikationsrobustheit oder Sicherheitszonierung entscheidend sind, etwa in Umspannwerken, Converter Stations, Windturbinen-Gateways oder industriellen Netzsegmenten. Mobile Endgeräte spielen eine Rolle im Service- und Instandhaltungskontext, insbesondere wenn Diagnosen, Checklisten, Bilddaten oder Assistenzfunktionen vor Ort benötigt werden. TinyML wiederum wird dort relevant, wo sehr kleine, energiearme Sensorknoten Frühindikatoren erfassen sollen, bevor größere Datenströme ausgelöst werden.

Aus technischer Sicht ist das zentrale Entwurfsmuster daher meist: lokale Vorverarbeitung und Detektion, zentrale Korrelation und Orchestrierung. Ein lokales System erkennt beispielsweise eine

ungewöhnliche Vibrationssignatur oder ein Kommunikationsmuster, ohne bereits die vollständige kausale Diagnose zu liefern. Die eigentliche Einordnung erfolgt dann in einer zentralen Plattform, die historische Daten, Flottenwissen, Umweltbedingungen, Wartungshistorie und Systemtopologie hinzuzieht. Dieses Muster ist für Wind- und Netzbetrieb deshalb so passend, weil es Robustheit, Sicherheitszonierung und Skalierbarkeit miteinander verbindet.

3.2 Produktionsbetrieb, MLOps und OT Security

Damit ein solches System im Betrieb tragfähig ist, braucht es MLOps als echte Betriebsdisziplin. Modelle altern, Datenregime ändern sich, Sensoren driften, Ersatzteile verändern das Verhalten eines Subsystems, neue Betriebsmodi entstehen und externe Einflussgrößen verschieben Wahrscheinlichkeiten. In der Windenergie kommen Wetterregime, Saisonalität, Parkumbauten und OEM-spezifische Unterschiede hinzu; im Netzbetrieb Topologieänderungen, Schutzkonzepte, Lastverschiebungen, neue Einspeiser und IT/OT-Interaktionen. Ein Modell, das bei der Inbetriebnahme gut funktioniert, kann daher Monate später bereits unzuverlässig sein. Drift-Monitoring, Revalidierung, kontrollierte Rollouts, Fallback-Mechanismen und dokumentierte Eingriffsrechte sind deshalb keine Zusatzfunktionen, sondern Teil der sicherheits- und qualitätsgerechten Betriebsführung.

Mit agentischen Workflows erweitert sich diese Betriebsdisziplin über MLOps und LLMOps hinaus zu Agent Operations. Kontextquellen, Prompts, Werkzeuge, Berechtigungen und Workflowlogik verändern sich im Betrieb und benötigen Versionierung, Evaluation, Regressionstests, Zugriffskontrolle, Logging, Incident Handling, Kostenüberwachung und definierte Serviceerwartungen. Jede Werkzeugberechtigung sollte gegen die Assets, Prozesse und Abhängigkeiten geprüft werden, die sie beeinflussen kann. Sinkt die Qualität der Evidenz, fallen unterstützende Services aus oder verlieren Berechtigungen ihre Gültigkeit, muss die zulässige Autorität reduziert, eine Aktion zurückgestellt oder an die verantwortliche menschliche Rolle übergeben werden.

Im Kontext von Windparks, Umspannwerken, Converter Stations und Leitstellen skaliert KI ohne OT-Cybersecurity nicht. Der Grund ist banal, aber folgenreich: In OT ist Verfügbarkeit und Betriebssicherheit oft wichtiger als „klassische“ IT-Sicherheitsprinzipien, und viele IT-zentrierte Controls sind in OT nicht ohne Nebenwirkungen einsetzbar. Sobald ML-Pipelines, Edge-Analytics, Remote-Zugriffe, Cloud-Korrelation oder GenAI-Assistenz in technische Betriebsprozesse eingreifen, vergrößert sich die Angriffsfläche, und damit steigt der Bedarf an einem systematischen, nachhaltigen OT-Security-Programm. Dieses Programm ist weniger ein einmaliges Projekt als eine Betriebsdisziplin, die Risiko auf ein „as low as reasonably practicable“-Niveau bringt und dauerhaft hält. Praktisch braucht es dafür (i) [Commitment](#) auf Management-Ebene, (ii) ein [konsistentes Framework](#), das Engineering-, Betriebs- und Sicherheitsprozesse integriert, und (iii) [Umsetzungsdisziplin](#), inklusive Monitoring, Policy-Management, regelmäßiger Tests und klarer Verantwortlichkeiten. In OT gilt: Ohne belastbare Security- und Governance-Grundlage bleibt KI [Pilotitis](#), oder wird zum Betriebsrisiko. Identität, Leserechte, Vorschlagsrechte und Ausführungsrechte sollten getrennt geführt werden, damit die Reichweite eines Workflows seine operative Autorität nicht stillschweigend erweitert.

3.3 Von Decision Support zu Governed Operational Autonomy

Der Nutzen von ML und KI entsteht erst, wenn klar ist, welche Entscheidungen unterstützt werden, wer sie verantwortet und wie der Betrieb mit den Ergebnissen arbeitet. Mit wachsendem Zugriff

analytischer Systeme auf Kontext, Werkzeuge und Workflows werden Modellfähigkeit und operative Autorität zu getrennten Gestaltungsdimensionen. Ein System kann technisch in der Lage sein, eine Maßnahme vorzubereiten oder anzustoßen, während seine zulässige Rolle auf Beobachtung, Empfehlung oder Koordination begrenzt bleibt. Der angemessene Autoritätsgrad richtet sich nach Konsequenz, Reversibilität, Evidenzqualität und der verfügbaren Zeit für menschliches Eingreifen.

Agentic AI erweitert diese Betriebslogik, indem prädiktive Modelle, Optimierung, generative Modelle und deterministische Systeme über kontrollierte Workflows zusammengeführt werden. Der operative Wert liegt besonders in der Koordination von Handlungsoptionen über technische, kommerzielle, vertragliche und betriebliche Restriktionen hinweg. Coordinated Optionality wird dort relevant, wo mehrere zulässige Optionen um knappe Ressourcen, Zeitfenster, Betriebsreserven oder vertragliche Kapazität konkurrieren. Das System kann Optionen erhalten, vergleichen und zur Entscheidung routen, während materielle Festlegungen bei den verantwortlichen Rollen verbleiben.

Jeder Workflow mit operativer Reichweite benötigt deshalb ein explizites Mandat. Dieses beschreibt Zweck, verantwortliche menschliche Rolle, freigegebene Evidenzquellen, zulässige Werkzeuge, Decision Rights, Betriebsgrenzen, Eskalationsweg, Leistungskriterien und Überprüfungstermin. Autorität gilt nur innerhalb des freigegebenen Operating Envelope. Änderungen an Werkzeugen, Evidenzquellen oder Ausführungsrechten erfordern eine kontrollierte Betriebsfreigabe.

Governed Autonomy ordnet diese Autorität proportional. Observe umfasst Monitoring, Verdichtung, Mustererkennung und das Sichtbarmachen relevanter Signale. Advise bereitet Empfehlungen, Alternativen und Unsicherheitsaussagen auf. Coordinate bündelt Evidenz, routet Aufgaben und steuert Abhängigkeiten. Act with Approval erlaubt werkzeuggestützte Aktionen nach expliziter menschlicher Bestätigung oder definierter Workflowfreigabe. Bounded Execution erlaubt begrenzte selbständige Ausführung innerhalb eines freigegebenen Betriebsrahmens mit Monitoring, Eingriffsrechten und Fallback.

Auch der Betriebszustand muss den zulässigen Autonomiegrad beeinflussen. Im Normalbetrieb kann die freigegebene Autorität genutzt werden, wenn Evidenz, Kontext, Modellgültigkeit und Systemverfügbarkeit die erforderlichen Schwellen erfüllen. In einem eingeschränkten Zustand wird Autorität reduziert, sobald Kontext oder Datenqualität abnehmen. Im degradierten Zustand werden Aktionen zurückgestellt oder an die verantwortliche menschliche Rolle übergeben. Die Wiederherstellung des vorherigen Autoritätsniveaus setzt Revalidierung voraus.

In physischer Energieinfrastruktur braucht Governed Autonomy zusätzlich eine klare Grenze zwischen übergeordneter Intelligenz und technischer Regelung. KI kann Zustände schätzen, Entwicklungen prognostizieren, Betriebspunkte optimieren und Workflows innerhalb freigegebener Grenzen koordinieren. Sicherheitsfunktionen, Schutz und schnelle Regelkreise bleiben deterministisch, wenn der technische Safety Case dies verlangt. Lesender Zugriff, Kommandorechte und administrative Rechte benötigen jeweils eigene Berechtigungen und eigene Fehlerbehandlung.

4. Methodik: Algorithmische Klassen, mathematische Kerndefinitionen und Datenlogik (Wind & Netz)

Wer KI/ML in Windenergie und Netzbetrieb ernsthaft engineering-ready diskutieren will, sollte die Verfahren nicht primär nach „Hype-Level“, sondern nach ihrer mathematischen Grundstruktur ordnen. Abbildung 1 ordnet AI/ML/RL/DL in der Schnittmenge zwischen Statistik, IT, und operativen Betrieb (operations, automation,

actuation) ein. In allen Fällen wird eine Abbildung zwischen beobachtbaren Größen x (Features, Messwerte, Kontext) und einer Zielgröße y (Prognose, Klasse, Entscheidung, Kostenfunktion) gesucht, und in allen Fällen entscheidet die Qualität der Inputdaten darüber, ob das Ergebnis belastbar ist oder nur plausibel aussieht.




Abb. 1: AI/ML/RL/DL in Schnittmenge zwischen Statistik, IT und operativen Betrieb

In diesem Sinn ist ML/AI tatsächlich oft „nur“ eine Erweiterung der klassischen Modellwelt: Anstelle einfacher linearer Abbildungen treten nichtlineare Funktionsklassen; anstelle deterministischer Punktschätzungen treten probabilistische Modelle; anstelle einmalig definierter Optimierungsprobleme treten lernende oder adaptive Entscheidungsregeln. Der Kern bleibt: Ohne saubere Messketten, konsistente Prozesse und eine tragfähige IT/OT-Architektur ist auch das beste Modell wertlos.

4.1 Closed-Loop Intelligence: KI als Betriebsdisziplin kontinuierlicher Verbesserung in kritischer Infrastruktur

Eine belastbare KI-Architektur in kritischer Infrastruktur lässt sich am treffendsten als Closed-Loop-Disziplin verstehen. Ihr Wert erschöpft sich nicht in präziseren Prognosen, schnellerer Anomalieerkennung oder leistungsfähigeren Modellen. Strategisch relevant wird sie dort, wo operative Evidenz in belastbares organisationales Lernen überführt wird, wo dieses Lernen Planungs- und Betriebsannahmen verändert und wo daraus wiederum verbesserte operative Entscheidungen entstehen. An diesem Punkt verlässt KI die Sphäre punktueller Analyse und wird Teil einer Führungs- und Betriebsdisziplin. Genau darin liegt ihre Nähe zu einem Continuous Improvement Programme: Beobachtung, Einordnung, Überprüfung von Annahmen, Anpassung und erneute Umsetzung werden zu einer strukturierten Schleife verbunden.

Diese Perspektive ist im Energiesektor deshalb besonders tragfähig, weil technische Infrastrukturen ihren tatsächlichen Charakter erst im Betrieb offenlegen. Windparks, Umspannwerke, Konverterstationen, Speicher und netznahe Betriebsprozesse zeigen ihre relevanten Muster nicht bei der Inbetriebnahme, sondern unter realen Wetterregimen, Lastsituationen, Eingriffen, Störungen, Wartungsereignissen, Engpässen und wechselnden Markt- und Netzbedingungen. Der betriebliche Erkenntnisgewinn entsteht somit nicht allein aus dem Modell, sondern aus der Fähigkeit, wiederkehrende Signale in einen lernfähigen Handlungszusammenhang einzubetten. Eine ernsthafte KI-Logik braucht deshalb mehr als mathematische Güte. Sie braucht eine strukturierte Rückkopplung zwischen Wahrnehmung, Vorausschau, Entscheidungsvorbereitung, Umsetzung, Validierung und erneuter Justierung.

Genau an dieser Stelle erweitert sich die Rolle von KI um eine vierte, häufig unterschätzte Funktion. Neben Wahrnehmung, Vorausschau und Entscheidungsvorbereitung trägt sie zur Institutionalisierung von Lernen bei. Sie macht sichtbar, welche Annahmen robust bleiben, welche Betriebsregeln zu konservativ oder zu fragil geworden sind, wo Planungsprämissen nicht mehr zur beobachtbaren Realität passen und an welchen Stellen Instandhaltungs-, Dispatch- oder Betriebsgrenzen neu kalibriert werden sollten. Der eigentliche Managementwert von KI liegt damit nicht nur in besserer Erkennung oder besserer Vorhersage, sondern in der Fähigkeit, Evidenz in Verbesserung zu überführen.

Viele Organisationen erzeugen die Rohsubstanz für dieses Lernen bereits heute, ohne sie systematisch zu nutzen. Wiederkehrende Anschlussablehnungen, saisonale Auslastungsasymmetrien, regelmäßig auftretende Curtailment-Muster, unzureichend genutzte Flexibilitätsoptionen, instandhaltungsbedingte Engpässe oder dauerhafte Abweichungen zwischen Soll- und Ist-Verhalten bleiben oft in lokalen Routinen, Ticketsystemen, Betriebsbesprechungen oder Einzelfallentscheidungen gebunden. Für sich genommen wirken solche Beobachtungen operativ begrenzt. In ihrer zeitlichen Verdichtung bilden sie jedoch eine hoch relevante Evidenzbasis für bessere Planung, glaubwürdigere Priorisierung, präzisere Betriebslogiken und reifere Governance. Closed-Loop Intelligence erschließt genau diese Ebene. Sie verbindet operative Spuren mit Managementurteil und längerfristiger Verbesserung.

Daraus folgt unmittelbar, dass die Schlüsselfrage weniger lautet, wie anspruchsvoll ein Modell mathematisch ist, als wie tragfähig die Schleife selbst gestaltet ist. Für diese Rückkopplung bewährt sich eine fünfstufige Lernlogik. Erstens wird Evidenz aus Betrieb, Engineering, Markt- und Netzschnittstellen, Wartungshistorien und Kontextdaten systematisch erfasst. Zweitens verdichtet KI diese Evidenz zu Mustern, Wahrscheinlichkeiten, Abweichungen und Handlungsräumen. Drittens werden diese Ergebnisse gegen Zielsysteme, Restriktionen, Eskalationslogiken und Verantwortlichkeiten gespiegelt. Viertens werden Entscheidungen in Planungsannahmen, Betriebsgrenzen, Instandhaltungskonzepte oder operative Verfahren übersetzt. Fünftens werden die Wirkungen dieser Entscheidungen beobachtet und genutzt, um sowohl Modelle als auch Regelwerke nachzuschärfen. Kontinuierliche Verbesserung wird damit nicht zum Reflex, sondern zu einer belastbaren Betriebslogik in datenreichen technischen Umgebungen.

In diesem Verständnis wirkt KI als Verstärker disziplinierten Managements. Urteilkraft, Abwägung und Verantwortung verbleiben dort, wo Zielkonflikte real entschieden werden müssen: zwischen Verfügbarkeit und Degradation, zwischen Kosten und Resilienz, zwischen Sicherheitsmargen und Auslastung, zwischen regulatorischer Nachweisfähigkeit und operativer Geschwindigkeit. In kritischer Infrastruktur ist deshalb nicht entscheidend, ob ein Modell eine Antwort erzeugen kann, sondern ob diese Antwort in einen verantwortbaren Entscheidungspfad eingebettet werden kann. Eingriffsrechte, Validierungslogiken, Fallbacks und Zuständigkeiten sind deshalb keine nachgelagerten Ergänzungen, sondern konstitutiver Teil der Schleife.

Der betriebliche Nutzen dieser Logik ist erheblich. Sie verringert den Abstand zwischen Beobachtung und Konsequenz. Sie stärkt die Verbindung zwischen Betrieb und Planung. Sie schafft einen organisationalen Rhythmus, in dem Annahmen regelmäßig überprüft, Muster eingeordnet und Anpassungen kumulativ wirksam werden. Für Führungsteams ist dies von besonderer Bedeutung, weil belastbare Verbesserung nicht aus Reporting-Dichte entsteht, sondern aus der Fähigkeit, Erfahrung in bessere künftige Entscheidungen zu überführen. KI kann diesen Übergang

erheblich beschleunigen, sofern sie in eine Struktur eingebettet ist, die Nachvollziehbarkeit, Reflexion und iterative Anpassung als Normalfall behandelt.

Closed-Loop Intelligence lässt sich damit als praktische Architektur kontinuierlicher Verbesserung in kritischer Infrastruktur lesen. Sie verleiht technischen Systemen ein belastbareres Gedächtnis, Organisationen einen disziplinierten Lernmodus und dem Management eine robustere Grundlage für Anpassung unter Unsicherheit. Ihre strategische Relevanz liegt in der Verdichtung der Schleife zwischen operativer Evidenz, Führungsurteil, strukturierter Verbesserung und aktualisierten Planungsannahmen. Genau dort gewinnt KI dauerhafte Bedeutung: nicht als singuläres Werkzeug, sondern als Betriebsdisziplin intelligenter Weiterentwicklung.

4.2 Regressionsmodelle: Von der linearen Baseline zur probabilistischen Vorhersage

Der Einstiegspunkt vieler Energie-Use-Cases ist die Regression: Es soll ein kontinuierlicher Wert vorhergesagt werden - etwa Leistung, Einspeisung, Last, Temperatur, Zustandsindikatoren oder Kosten. Die lineare Regression ist dabei sowohl ein didaktisches Beispiel als auch ein wichtiger Engineering-Baustein, weil sie transparent, stabil und als Baseline unverzichtbar ist. Formal werden Parameter β (und ggf. ein Interzept b) so gewählt, dass die Summe quadratischer Fehler minimiert wird:

$$\min_{\beta, b} \sum_{i=1}^n (y_i - (\beta^T x_i + b))^2.$$

Die „Inputdaten“ sind hier nicht anders als bei multivariater Regression im klassischen Sinne: ein Feature-Vektor x_i , eine Zielgröße y_i , und vor allem eine definierte Zuordnung, wann x zu welchem y gehört. In der Windenergie ist diese Zuordnung heikel, weil SCADA-Werte, Curtailment-Flags, Störungen, Wartungszustände und Wetterregime in der Zeit nicht sauber getrennt sind. Ein Modell, das Leistung aus Windgeschwindigkeit lernt, lernt im Zweifel nicht Aerodynamik, sondern die Häufigkeit von Curtailment oder die Signatur bestimmter Abregelstrategien. Die scheinbar triviale Anforderung „Zeitachsen sind synchron, Ausfälle sind maskiert, Betriebsmodi sind bekannt“ ist deshalb nicht nebensächlich, sondern die eigentliche Voraussetzung für Erkenntnis.

Wo ML/AI über die klassische Regression hinausgeht, ist weniger die Existenz von Inputdaten, sondern (i) die Nichtlinearität der Funktionsklasse und (ii) die Unsicherheit der Vorhersage. Für operative Entscheidungen ist ein Konfidenzband oft wichtiger als ein Mittelwert. Probabilistische Regression modelliert daher sowohl den Erwartungswert $E[y|x]$ als auch eine Verteilung $p(y|x)$ oder zumindest Quantile. Typisch ist die Quantilschätzung über die Pinball-Loss-Funktion; für ein Quantil $\tau \in (0,1)$ wird eine Vorhersage $\hat{y}_\tau(x)$ so trainiert, dass Über- und Unterschätzungen asymmetrisch bestraft werden. Genau an dieser Stelle verbindet sich „ML“ sehr direkt mit einem häufig beobachtbaren Optimierungsdenken: Die Zielfunktion wird nicht als kosmetisches Detail betrachtet, sondern als codierte ökonomische Realität - inklusive asymmetrischer Kosten, Sicherheitsmargen und Risikoaversion.

Praktisch zeigt sich hier sofort, ob die IT- und Prozesslandschaft „KI-fähig“ ist: Wenn Forecast-Features aus NWP-Ensembles, SCADA, Parktopologie und Netzzuständen kommen, dann muss klar sein, welche Version eines Wettermodells vorlag, ob Curtailment korrekt gekennzeichnet ist, ob Messwerte nachträglich korrigiert wurden, und ob die Feature-Bildung reproduzierbar ist. Ohne Datenversionierung, Feature-Definitionen und Lineage werden Prognosen beliebig; mit ihnen werden Prognosen belastbare Betriebsmittel.

4.3 Klassifikation: Ereignisse, Fehlerbilder und Entscheidungsauslöser

Viele der wertvollsten Anwendungen im Betrieb sind binär oder kategorial: Ausfall ja/nein, Fehlerklasse A/B/C, Anomalie vs. Normalbetrieb, „kritischer Zustand“ vs. „unkritisch“. Mathematisch ist die logistische Regression der prototypische Einstieg. Sie modelliert eine Wahrscheinlichkeit

$$p(y = 1|x) = \sigma(\beta^T x + b), \quad \sigma(z) = \frac{1}{1+e^{-z}},$$

und wird typischerweise über Kreuzentropie trainiert. Auch hier sind Inputdaten nicht weniger existentiell als in klassischen Verfahren; im Gegenteil: Das gesamte Problem steht und fällt mit Labels. In Wind und Netz sind Labels aber selten „Laborlabels“. Sie entstehen in Ticket-Systemen, Wartungsberichten, Alarmtexten, Schutzrelaislogs, OEM-Codes und menschlichen Einschätzungen. Wenn CMMS, SCADA, Leitsystem und Asset-Register nicht konsistent integriert sind, entsteht kein zuverlässiges y . Dann wird Klassifikation zum Versuch, aus uneinheitlichen Textfragmenten eine vermeintliche Ground Truth zu erzeugen - mit entsprechend hohem Risiko für Scheinkorrelationen.

Ein praktischer Engineering-Weg besteht häufig darin, Klassifikation nicht als „vollautomatische Entscheidung“ zu betreiben, sondern als Priorisierung: Welche Ereignisse sind so ungewöhnlich, dass sie eskaliert werden müssen? Welche Alarmer sind vermutlich Folgesymptome statt Ursachen? Welche Kombination aus Zustandsindikatoren und Kontext weist auf einen beginnenden Schaden hin? Diese Interpretation als Entscheidungsauslöser passt sehr gut zu sicherheitskritischer Infrastruktur, weil sie Mensch und Prozess nicht ersetzt, sondern fokussiert.

4.4 Bäume, Ensembles und robuste Nichtlinearität

Entscheidungsbäume und insbesondere Random Forests sind in der industriellen Praxis beliebt, weil sie mit Mischdaten gut umgehen und häufig „robuste“ erste Ergebnisse liefern, ohne dass extreme Feature-Engineering-Disziplin nötig ist. Mathematisch ist ein Entscheidungsbaum eine rekursive Partition des Feature-Raums; ein *Random Forest* mittelt viele solche Bäume, typischerweise

$$\hat{f}(x) = \frac{1}{T} \sum_{t=1}^T f_t(x),$$

wobei f_t auf Bootstrapsamples und zufälligen Feature-Subsets trainiert wird. Für Wind-/Netz-Use-Cases sind solche Modelle oft pragmatisch, weil sie nichtlineare Zusammenhänge zwischen Betriebsmodus, Wetter, Alarmmustern und Zustandsvariablen erfassen können, ohne dass man sofort in tiefe neuronale Architekturen gehen muss.

Die Schattenseite ist weniger mathematisch als organisatorisch: Sobald mehrere Teams oder Lieferanten Features „ähnlich, aber nicht identisch“ berechnen, zerfällt die Reproduzierbarkeit. Dann ist nicht mehr klar, ob ein Modell besser wurde oder ob nur die Feature-Bildung unbemerkt geändert wurde. Genau hier entsteht der Punkt, an dem KI/ML sich von klassischer Statistik im betrieblichen Sinne unterscheidet: Ohne Feature-Store-Logik, Versionierung, Schema-Management und Monitoring wird die Modellleistung nicht „schlecht“, sondern uninterpretierbar.

4.5 Unsupervised Learning: Regime, Zustände und Anomalien ohne Labels

Ein großer Teil der Betriebswirklichkeit ist nicht sauber gelabelt. Man weiß, dass etwas „anders“ ist, aber nicht, wie es zu benennen ist. Hier sind unüberwachte Verfahren wie Clustering, Dimensionsreduktion und Autoencoder praktisch relevant. k-means Clustering formalisiert die Idee, dass Datenpunkte sich um k Zentren gruppieren; es minimiert

$$\min_{\{\mu_j\}} \sum_{i=1}^n \min_{1 \leq j \leq k} |x_i - \mu_j|^2.$$

In Windparks kann k-means beispielsweise Betriebsregime trennen: Normalbetrieb, Curtailment, vereisungsähnliche Muster, Sensor-Drift-Cluster. Im Netzbetrieb lassen sich Regime in Mess- und Ereignisdaten identifizieren, die bestimmten Topologie- oder Lastsituationen entsprechen.

PCA (Principal Component Analysis) reduziert Dimensionen, indem sie die Hauptrichtungen maximaler Varianz über Eigenvektoren der Kovarianzmatrix $\Sigma w = \lambda w$ findet. Im CMS-Kontext dient das oft dazu, Spektraldaten oder multivariate Zeitreihen auf wenige stabile Faktoren zu verdichten, bevor man Anomalie- oder RUL-Modelle darauf aufsetzt. *Autoencoder* gehen einen Schritt weiter: Sie lernen eine komprimierte Darstellung $z = g_\phi(x)$ und rekonstruieren $\hat{x} = h_\theta(z)$ durch Minimierung eines Rekonstruktionsfehlers

$$\min_{\phi, \theta} \sum_i |x_i - h_\theta(g_\phi(x_i))|^2.$$

Anomalien erscheinen dann als hohe Rekonstruktionsfehler oder ungewöhnliche Latent-Space-Lagen. Der entscheidende Punkt ist jedoch nicht die Formel, sondern der Begriff „Normalbetrieb“. Wenn Normaldaten bereits verdeckte Störungen, Wartungsartefakte oder systematische Curtailment-Muster enthalten, lernt das Modell genau diese Welt als normal. Unsupervised Learning ist deshalb besonders stark, wenn die Prozesslandschaft Betriebsmodi sauber definiert und die IT-Landschaft Datenqualitätsmerkmale (Vollständigkeit, Plausibilität, Freshness, Consistency) sowohl formal fordert als auch messbar macht.

4.6 Bayes und Unsicherheit: Von Punktwerten zu Verteilungen

In Wind und Netz ist Unsicherheit keine Störung, sondern Normalzustand. Bayessche Modelle machen diese Unsicherheit explizit, indem sie Parameter θ probabilistisch behandeln und nach Beobachtung von Daten D per Bayes aktualisieren:

$$p(\theta|D) = \frac{p(D|\theta)p(\theta)}{p(D)}.$$

Der praktische Nutzen liegt weniger im philosophischen Charme, sondern in der Fähigkeit, epistemische Unsicherheit sichtbar zu machen: Was weiß das Modell tatsächlich, und wo extrapoliert es? Gerade bei seltenen Ereignissen (schwere Störungen, seltene Ausfallmodi, Extremwetter) ist diese Unterscheidung entscheidend. Ein probabilistisches Modell kann dann bewusst konservativ werden - und zwar nicht als Bauchgefühl, sondern als quantifizierte Risikoentscheidung.

Die Achillesferse ist wiederum die operative Realität: Wenn Messdefinitionen, Sensoren oder Kalibrierungen geändert werden, ändern sich die Fehlerverteilungen. In der Bayes-Welt bedeutet das: Die Likelihood passt nicht mehr, das Posterior wird falsch, und ohne Lineage/ Change-Logs merkt man es erst, wenn Entscheidungen scheitern. Bayes belohnt saubere Systemführung und bestraft stille Systembrüche.

4.7 Gaussian Processes, Bayesian Optimization und „Safe Exploration“: Optimierung unter Betriebsrestriktionen

Viele Optimierungsprobleme in Wind und Netz sind entweder (a) zu *teuer*, um sie „hart“ zu lösen, (b) zu *unsicher*, um ihnen zu vertrauen, oder (c) zu *riskant*, um beliebige Evaluierungen zuzulassen. Genau dafür sind Surrogate-Modelle und Bayessche Optimierung attraktiv: Man lernt eine Ersatzfunktion, die Mittelwert und Unsicherheit liefert, und wählt Evaluierungspunkte so, dass man effizient lernt und zugleich Risiken begrenzt.

Gaussian Processes (GP) modellieren eine Verteilung über Funktionen

$$f(x) \sim \mathcal{GP}(m(x), k(x, x')).$$

Nach Beobachtungen erhält man einen Posterior mit Mittelwert $\hat{\mu}(x)$ und Varianz $\hat{\sigma}^2(x)$. In der Bayesschen Optimierung ist die nächste Evaluierung dann typischerweise ein Kompromiss aus „vielversprechend“ und „informationsreich“ (exploitation vs. exploration). Im industriellen Betrieb ist aber oft entscheidender, dass Evaluierungen nicht „unsafe“ sein dürfen. Deshalb ist Safe Optimization relevant: Man führt Konfidenzschranken $u(x), l(x)$ und eine Sicherheitsbedingung ein, die probabilistisch garantiert, dass Grenzen (z. B. Lasten, Spannungen, Temperaturen, Betriebsgrenzen) nicht überschritten werden. Damit wird die Optimierung zu einer Methodik, die eine klassische Restriktionslogik (Constraints) nicht ersetzt, sondern probabilistisch erweitert.

Das praktische Beispiel ist Wake-Steering oder Reglertuning: Man will mehr AEP, aber keine übermäßigen Lasten und keine unkontrollierten Betriebszustände. Ohne kontextreiche Daten wie Windrichtung, Turbulenz, Betriebsmodus, Curtailment, Topologie, kann man den Effekt einer Stellgröße nicht identifizieren. Ohne kontrolliertes Change-Management kann man den Effekt nicht kausal zuordnen. Und ohne hochfrequente, frische Datenketten wird die Optimierung zu einem Ratespiel. In diesem Sinne ist Safe Bayesian Optimization ein Musterbeispiel dafür, dass „KI“ nicht die Abwesenheit klassischer Engineering-Disziplin bedeutet, sondern deren Verstärkung.

4.8 Reinforcement Learning: Sequenzielles Entscheiden – aber nur mit Digital Twin und Safety Case

Reinforcement Learning (RL) ist die algorithmische Klasse, die am stärksten „AI“ konnotiert ist, aber im Betrieb kritischer Infrastruktur die strengsten Bedingungen benötigt. Formal wird ein Problem als Markov Decision Process $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$ modelliert; gesucht ist eine Policy $\pi(a|s)$, die den erwarteten diskontierten Return maximiert:

$$\max_{\pi} E \left[\sum_{t=0}^{\infty} \gamma^t r_t \right]$$

Q-learning aktualisiert eine Aktionswertfunktion über

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)].$$

In Wind und Netz klingt das verführerisch, weil viele Probleme sequenziell sind: Dispatch, Wartungskampagnen, Wake-Steering, Engpassmanagement. Der Engineering-Haken ist, dass RL klassisch durch Versuch und Irrtum („trial-and-error“) lernt, was in kritischer Infrastruktur „unsafe exploration“ bedeutet. Deshalb ist der realistische Pfad fast immer simulationsgetrieben: RL in einem Digital Twin (physikalisch + betrieblich), Evaluation unter Stress-Tests, konservative Guardrails und erst dann, wenn überhaupt, ein Übergang in Advisory Mode oder eng begrenzte kontrollierte Automatisierung. RL ist damit nicht „das bessere MPC“, sondern eine Methodik für Situationen, in denen man eine gute Simulationsumgebung besitzt und Policies unter Unsicherheit robust machen will. Ohne Twin, ohne Datenkonsistenz, ohne Change-Disziplin ist RL nicht „schwierig“, sondern unverantwortlich.

4.9 GenAI und RAG: Wissensarbeit mit Provenienz statt „kreative Antworten“

Generative KI ist im Wind-/Netz-Kontext vor allem dann wertvoll, wenn sie Wissensarbeit strukturiert: Manuals, Standards, As-built-Dokumente, Wartungsberichte, Lessons Learned, Alarmtexte, Spezifikationen, Protokolle. Das zentrale Muster für produktive Nutzung ist Retrieval-Augmented Generation (RAG):

Statt das Modell frei halluzinieren zu lassen, wird Kontext aus einer kontrollierten Wissensbasis abgerufen. Technisch heißt das: Dokumente werden in **Embeddings** $e(d) \in R^k$ überführt; eine Query q ebenfalls. Man sucht Top-K Dokumente über Ähnlichkeit, etwa per Cosine Similarity

$$\text{sim}(q, d) = \frac{e(q) \cdot e(d)}{|e(q)| |e(d)|},$$

und generiert die Antwort konditioniert auf diese Quellen.

Im industriellen Betrieb ist der kritische Punkt nicht „kann das Modell antworten“, sondern „darf es das - und ist die Antwort beweisbar“. Provenienz, Rechte, Audit-Logs, Rollenmodelle, Datenklassifikation und Aktualität sind hier die Kernbedingungen. Wenn die Dokumentenlandschaft fragmentiert ist, wenn es keine Single Source-of-Truth gibt, wenn Versionen unklar sind oder Zugriffsrechte nicht sauber modelliert sind, dann skaliert GenAI nicht, oder skaliert Risiken. RAG ist daher weniger ein NLP-Trick als ein Architekturprinzip: kontrollierte Informationsbereitstellung mit Quellenbindung.

5. Der gemeinsame Nenner: Daten sind sowohl Input als auch Teil des Systems

Wenn man diese Algorithmusklassen nüchtern betrachtet, bestätigt sich meine Beobachtung: Die Inputdaten sind in ihrer Existenzialität vergleichbar mit multivariater Regression oder MICQP, nur dass die Anforderungen in KI/ML oft noch strenger sind, weil Modelle adaptiv sind, weil sie in der Fläche ausgerollt werden, und weil sie in nicht-stationären Umgebungen leben. In Wind und Netz sind Daten Teil eines socio-technischen Systems, nämlich Rohstoff und Betriebsgrundlage. Ohne klare Prozesse, Zuständigkeiten und IT/OT-Integrationsarchitektur entstehen drei typische Pathologien.

- Erstens die Pathologie der **inkonsistenten Zeit**: Sensoren, SCADA, CMMS, Wettermodelle und Netzereignisse leben auf unterschiedlichen Zeitskalen und Zeitstempeln. Ohne definierte Synchronisationslogik wird jede Kausalinterpretation brüchig.
- Zweitens die Pathologie des **fehlenden Kontexts**: Betriebsmodi, Wartungszustände, Firmwarestände, Curtailment und Topologieänderungen werden nicht sauber als Kontextvariablen geführt; dann lernen Modelle „Betriebspolitik“ statt „Systemverhalten“.
- Drittens die Pathologie der **nicht reproduzierbaren Features**: Wenn Feature-Bildung nicht versioniert, auditiert und überwacht wird, dann werden Modelle zu Artefakten einzelner Notebook-Läufe. Genau hier liegt die operative Wahrheit von „KI-Fähigkeit“: nicht in der Wahl des Algorithmus, sondern in der Fähigkeit, Daten, Features, Modelle und Entscheidungen als durchgängige Kette zu betreiben.

Kapitel 3 hat gezeigt, dass operative Autorität von der Qualität der Evidenz abhängt. Auf Datenebene wird ein Messwert, ein Modellergebnis oder ein abgerufenes Dokument entscheidungsfähig, wenn Quelle, Zeitbezug, Version, Betriebszustand, Ownership, Zugriffsrechte und Lineage erhalten bleiben. Derselbe Wert kann je nach Aktualität, Validierung und Autorität für die konkrete Entscheidung ein unterschiedliches Gewicht besitzen. Zusammen bilden diese Elemente eine Evidence Spine, die Beobachtung, Modellergebnis, Entscheidung, Umsetzung und anschließendes Lernen verbindet.

Die Architektur sollte dabei autoritative Datensätze und abgeleitete Intelligenz klar unterscheiden. SCADA, BMS, CMMS, ERP, ETRM und andere operative Systeme führen weiterhin den Zustand, für den sie fachlich verantwortlich sind. Validierte Modelle liefern Prognosen, Schätzungen und Optimierungsergebnisse. Agentische Workflows führen Kontext zusammen, bereiten Optionen vor und

koordinieren Aktionen über kontrollierte Schnittstellen. Abgerufene Inhalte, Modellinferenz und Workflow Memory besitzen damit unterschiedliche Evidenzqualität und müssen auf Quelle und Version zurückführbar bleiben.

Skalierung verlangt zusätzlich semantische Konsistenz. Assets, Komponenten, Netzanschlusspunkte, Betriebszustände, Verträge, Ereignisse und Workflowobjekte brauchen stabile Identitäten und eine systemübergreifend konsistente Bedeutung. Ein technisch vollständiger Datenexport kann operativ wenig wert sein, wenn die Zielumgebung diese Zusammenhänge nicht rekonstruieren kann. Eine gesteuerte semantische Schicht oder eine fortlaufend gepflegte kanonische Repräsentation erhält Bedeutung über Plattformgrenzen hinweg und reduziert die Abhängigkeit von einer einzelnen Anwendung als einzigem Träger kritischen Betriebskontexts.

Man könnte sagen: ML/AI erweitert die klassische Modellwelt um reichere Funktionsklassen und Unsicherheitslogik – aber die Governance- und Datenanforderungen bleiben nicht gleich, sondern steigen. Oder anders: ML/AI ist selten „eine neue Mathematik“, aber fast immer eine neue Betriebsdisziplin für Mathematik in lebenden Systemen.

Viele Use Cases werden erst durch eine Digital-Twin-Logik betriebsfähig. Ein Digital Twin ist dabei weniger ein 3D-Modell als eine operativ nutzbare Abbildung von Asset, Prozess oder Netzzustand, um Verhalten zu simulieren und Entscheidungen zu validieren. Drei Funktionen sind zentral: (i) *Zustands-/Belief-Twin* (z. B. SOC/SOH, Degradation), (ii) *physikalisch/regelungstechnischer Twin* (Wake, Lastfluss, inverterbasierte Dynamik), (iii) *operativer Twin* (O&M-Planung, Ressourcen, Freigaben). Der Twin ermöglicht Shadow-Tests, Stress-Tests und What-if-Analysen – und damit Safety Case und Nachweisfähigkeit.

Responsible AI sollte im Energiesektor nicht als abstrakte Ethikdebatte behandelt werden, sondern als laufende Governance-Funktion, die technische, regulatorische und betriebliche Anforderungen verbindet. In kritischer Infrastruktur geht es dabei um konkrete Eigenschaften: Nachvollziehbarkeit, Anfechtbarkeit, robuste Validierung, Missbrauchsschutz, Datenschutz und eine klare Verantwortungszuordnung über den gesamten Lebenszyklus von Daten, Modellen und Entscheidungen. Gerade weil viele Energiedaten personen- oder betriebsnah sind (z. B. netznahe Messwerte, Kundenlastprofile, Betriebsstörungen), und weil Fehlentscheidungen reale physische Konsequenzen haben können, muss Responsible AI als „Business-as-usual“-Disziplin verankert werden – nicht als einmalige Policy. In dieser Logik gewinnt Edge-AI zusätzliche Bedeutung: Modelle, die nahe am Asset oder in Sicherheitszonen betrieben werden, können Datenschutzanforderungen, Latenz und Resilienz besser erfüllen, sind aber nur dann verantwortbar, wenn sie in ein konsistentes Governance- und Monitoring-Regime eingebettet sind. Der Übergang von Piloten zu produktiven Systemen hängt damit nicht nur von Modellgüte ab, sondern davon, ob Organisationen in der Lage sind, Verantwortung, Evidenz, Risikosteuerung und Betriebssicherheit zusammenzuführen.

6. Exemplarische Use Cases für Wind & Netz

Abbildung 2 dient als Landkarte der im Papier beschriebenen Anwendungsfälle. Sie ordnet die Use Cases entlang zentraler Fähigkeitsklassen von KI/ML/GenAI – von Wahrnehmung und Prognose über Zustandsabschätzung bis zu Optimierung, Entscheidungsunterstützung und wissensbasierter Assistenz.

Die Abbildung erhebt bewusst keinen Anspruch auf Vollständigkeit, sondern soll als Strukturhilfe dienen: Sie macht sichtbar, welche methodischen Bausteine in welchen Use Cases dominieren und wo

gemeinsame Daten- und Betriebsanforderungen entstehen. Auf dieser Grundlage werden die folgenden Use Cases im Detail erläutert.




Abb. 2: Landkarte der Wind-/Netz-/BESS-Use-Cases, organisiert nach KI/ML-Fähigkeitsklassen

Use Case 1: Ertrags- und Einspeiseprognose

Die Ertrags- und Einspeiseprognose ist einer der naheliegendsten und zugleich technisch anspruchsvollsten Anwendungsfälle für ML im Windbereich. Während klassische Verfahren häufig mit deterministischen Wetterannahmen und vereinfachten Leistungskennlinien arbeiten, erlauben moderne ML-Ansätze eine differenziertere Verknüpfung von Wetterensembles, Turbinenzuständen, Curtailment-Situationen, Wake-Effekten und historischen Betriebsregimen. Entscheidend ist dabei weniger die bloße Punktprognose als die Fähigkeit, Unsicherheit explizit zu modellieren. Für operative Entscheidungen ist sowohl relevant, wie viel Leistung morgen voraussichtlich erzeugt wird, als auch mit welcher Wahrscheinlichkeit bestimmte Abweichungen auftreten können. Erst dadurch lassen sich Regelenergiebedarf, Redispatch-Risiken oder konservative Fahrweisen besser steuern.

Technisch bedeutet das, dass probabilistische Modelle, Quantilschätzer, kalibrierte Sequenzmodelle oder ensemblebasierte Ansätze oft geeigneter sind als reine Mittelwertschätzer. Besonders interessant wird dies auf mehreren Ebenen zugleich: Turbine, Park, Cluster, Portfolio und Netzknoten folgen nicht identischen Gesetzmäßigkeiten. Eine gute Modellarchitektur muss daher lokale Effekte wie Wake-Interaktionen und Turbinenverhalten ebenso abbilden wie systemische Einflüsse aus Wetter, Curtailment oder Netzengpässen. In der Praxis ist die ökonomische Wirkung solcher Modelle erheblich, weil Prognosefehler im Energiesystem asymmetrische Kosten auslösen. Eine kleine Verbesserung der Prognosegüte kann damit ökonomisch deutlich relevanter sein als eine große Verbesserung in einer rein statistischen Kennzahl.

Use Case 2: Predictive Maintenance und Restlebensdauer

Predictive Maintenance ist im Windbereich besonders wertvoll, weil ungeplante Ausfälle sowohl Reparaturkosten verursachen als auch häufig hohe Opportunitätskosten durch Stillstand, Sekundärschäden und komplizierte Offshore-Einsätze. Die Herausforderung besteht darin, dass viele kritische Degradationsprozesse nur indirekt beobachtbar sind. Lager, Pitchsysteme, Umrichter, Generatoren oder Triebstrangkomponenten zeigen frühe Auffälligkeiten oft nur in schwachen Signalen, verrauschten Spektren oder multivariaten Korrelationen. ML ist hier dann wirksam, wenn es nicht einfach

„Fehler“ klassifiziert, sondern Degradationspfade identifiziert und daraus eine belastbare Wartungslogik ableitet.

Methodisch reicht das Spektrum von klassischer Anomalieerkennung bis hin zu survival-basierten Ansätzen und Restlebensdauermodellen. Besonders wichtig ist, dass viele reale Datensätze nur wenige saubere Failure Labels enthalten. Die Praxis ist von unvollständigen Wartungsberichten, geänderten Komponentenständen, sensorischen Lücken und Confoundern geprägt. Ein Lager wird vielleicht ersetzt, bevor es ausfällt; ein Umrichter verhält sich nach Firmware-Änderung anders; eine Wartung beeinflusst die Signatur stärker als die eigentliche Alterung. Engineering-ready KI muss deshalb mit unvollständigen, verrauschten und teils verzerrten Labels umgehen können. Sie darf nicht nur Muster finden, sondern muss zwischen nützlichen Frühwarnsignalen und scheinbaren Korrelationen unterscheiden.

Gerade offshore entfaltet dieser Use Case besonderen Wert, weil hier die eigentliche Entscheidung nicht „Fehler ja oder nein“ lautet, sondern: Wann, mit welchem Team, mit welchem Material, bei welchem Wetterfenster und in welcher Kampagnenlogik greife ich ein? Der Predictive-Maintenance-Use-Case hat daher seine größte Wirkung nicht als isoliertes Diagnosemodell, sondern als Input in eine übergeordnete Einsatz- und Logistikoptimierung. Damit entsteht eine direkte Wertkette von Degradationssignalen über Eingriffszeitpunkt, Produktionsausfall und Ersatzteilbedarf bis zum Warranty Risiko. Mit wachsender Reife kann der Modellausgang in eine koordinierte Instandhaltungsvorbereitung einfließen, während die Eingriffsentscheidung bei den verantwortlichen Asset und Betriebsrollen bleibt.

Use Case 3: Rotorblattinspektion und Vision AI

Rotorblätter sind hochbeanspruchte Bauteile, deren Zustand unmittelbaren Einfluss auf Ertrag, Lastverhalten, Lebensdauer und Sicherheit hat. Klassische Inspektionen sind zeitaufwendig, personalintensiv und in ihrer Qualität teilweise stark von Erfahrung, Wetter, Sichtbedingungen und individueller Beurteilung abhängig. Vision-AI-basierte Verfahren versprechen hier nicht einfach Automatisierung, sondern eine Standardisierung der Wahrnehmung. Bild- und thermografie-basierte Verfahren können Erosion, Risse, Delaminationen oder Blitzschäden mit hoher Konsistenz vorerkennen und damit die Aufmerksamkeit gezielt auf kritische Befunde lenken.

Das eigentliche technische Problem liegt jedoch nicht allein in der Bildklassifikation, sondern in der Variabilität des Aufnahmeprozesses. Perspektive, Licht, Verschmutzung, Oberflächenzustand, Kameracharakteristik und Blattgeometrie beeinflussen das Ergebnis massiv. Gute Vision AI muss daher robust gegen Bedingungen sein, die im Labor kaum sauber reproduzierbar sind. Gleichzeitig genügt eine hohe durchschnittliche Erkennungsrate nicht, wenn gerade sicherheitskritische Defekte übersehen werden. Die operative Qualität eines solchen Systems bemisst sich daher weniger an einer abstrakten Modellmetrik allein als an der Frage, ob relevante Befunde zuverlässig eskaliert, sauber dokumentiert und in belastbare Instandhaltungsentscheidungen übersetzt werden. Genau deshalb bleibt der Mensch bei kritischen Klassen in der Verantwortung, nicht als Zeichen technischer Schwäche, sondern als Ausdruck eines vernünftigen Safety Case.

Use Case 4: Wake-Steering und Betriebsoptimierung

Die Optimierung des Parkbetriebs gehört zu den anspruchsvollsten KI-Anwendungen in der Windenergie, weil hier Aerodynamik, Strukturbelastung, Turbulenz,

Netzrestriktionen und wirtschaftliche Zielgrößen unmittelbar zusammenwirken. Wake-Steering ist ein typisches Beispiel dafür: Eine Turbine wird bewusst anders angeströmt oder ausgerichtet, um nachgelagerte Turbinen günstiger zu beeinflussen. Der Mehrertrag des Parks kann dadurch steigen, gleichzeitig verändern sich aber lokale Lasten, Ermüdungseffekte und Unsicherheiten. Das Problem ist daher kein rein datengetriebenes, sondern ein hybrides Optimierungsproblem an der Schnittstelle von physikalischem Modell, statistischer Unsicherheit und betrieblicher Restriktion. Hier zeigt sich besonders deutlich, dass KI im Engineering-Kontext nicht blind explorativ sein darf. Reinforcement Learning klingt in solchen Zusammenhängen attraktiv, ist in realen Anlagen aber nur unter strengen Bedingungen sinnvoll. Lernen durch Versuch und Irrtum ist in sicherheits- und haftungsrelevanten Systemen nur dort akzeptabel, wo Simulation, Digital Twin, konservative Guardrails und kontrollierte Freigabeprozesse vorhanden sind. Praktisch oft robuster sind deshalb surrogate-gestützte Optimierungsansätze, modellprädiktive Regelung oder bayesianische Verfahren, die mit Unsicherheit explizit umgehen und „unsafe exploration“ vermeiden. Der eigentliche Reifegradpfad führt daher fast immer über Simulation und Schattenbetrieb, bevor operative Empfehlungen oder automatisierte Stellgrößen überhaupt in Betracht kommen.

Use Case 5: Offshore O&M, Einsatz- und Kampagnenplanung

Offshore-Wind ist sowohl ein Asset- als auch ein Logistiksystem. Wetterfenster, Schiffskapazitäten, Crew-Verfügbarkeit, Ersatzteilzugang, Sicherheitsfreigaben und technische Prioritäten bilden ein hochgekoppeltes Betriebsproblem. Klassische Planungslogiken reagieren oft ereignisgetrieben und lokal, während der eigentliche Hebel in einer vorausschauenden Kampagnenbildung liegt. KI und fortgeschrittene Optimierung entfalten hier Nutzen, indem sie technische Befunde, Wetterprognosen und Ressourcenrestriktionen in rollierende Entscheidungsmodelle übersetzen.

Besonders wichtig ist, dass solche Modelle nicht einfach Kosten minimieren dürfen. Ein System, das Einsätze aggressiv verschiebt, mag kurzfristig wirtschaftlich erscheinen, kann aber Sicherheitsrisiken, Folgeausfälle oder systematische Überlastung von Crews erzeugen. In diesem Use Case wird damit exemplarisch deutlich, warum mehrzielige Optimierung im Energiesystem so zentral ist. Verfügbarkeit, Sicherheit, Kosten, Planstabilität und Ersatzteillöge sind nicht alternative Ziele, sondern müssen gemeinsam gedacht werden. Gute Modelle schaffen deshalb keine Scheingenauigkeit, sondern helfen, unter Zeit- und Restriktionsdruck bessere Prioritäten zu setzen. Mit wachsender Betriebsreife kann sich dieser Workflow von beratender Einsatzplanung zu koordinierter Aufgabenvorbereitung entwickeln. Schiffsbindung, Sicherheitsfreigaben und wesentliche Betriebsentscheidungen verbleiben bei den dafür benannten Rollen. Die wirtschaftliche Wirkung lässt sich über Schiffstage, vermiedene Produktionsverluste, Planstabilität und Verfügbarkeit besser erfassen als über Planungseffizienz allein.

Use Case 6: Netznahe Anomalieerkennung und Ereigniskorrelation

Im Netzbetrieb gewinnen datengetriebene Verfahren besonders dort an Wert, wo sich aus vielen unscheinbaren Signalen ein relevantes Muster zusammensetzt. Einzelne Schutzrelais-Events, Kommunikationsstörungen, Zeit-Synchronisationsprobleme, PMU-Abweichungen oder ungewohnte Lastflussbilder sind isoliert betrachtet oft harmlos.

In ihrer Kombination können sie jedoch auf beginnende Störungen, Messfehler, Fehlkonfigurationen oder Cyber-Indikatoren hinweisen. Der Mehrwert von KI liegt hier in der Korrelation heterogener Ereignisse über Zeit, Topologie und Systemgrenzen hinweg.

Methodisch ist dies ein Feld, in dem Zeitreihenanalyse, Graph-Modelle/ *Graph Neural Networks* (GNN) und regelbasierte Domänenlogik zusammengeführt werden müssen. Reine Black-Box-Modelle sind selten ausreichend, weil im Störfall Erklärbarkeit, Eskalationslogik und Vertrauenswürdigkeit entscheidend sind. Die beste Lösung ist deshalb häufig keine vollständig autonome Klassifikation, sondern ein Advisory Layer, der auffällige Muster priorisiert, visuell verdichtet und den Operator in die Lage versetzt, schneller und robuster zu handeln. Gerade im Netzbetrieb ist dies oft wirksamer als der Versuch, den Menschen aus der Schleife zu nehmen.

Wenn man KI im Netzbetrieb ernst nimmt, sollte man sie nicht nur als „Alarm-Korrelation“ oder „Decision Support“ diskutieren, sondern als Enabler für eine Klasse von netzstärkender („grid-enhancing“) Technologies, die physikalische Flexibilität und digitale Führbarkeit zusammenbringen. Dazu zählen dynamische Leistungsbewertung (Dynamic Line Rating), intelligentes Curtailment (statt pauschaler Abregelung), optimierte Blindleistungsbereitstellung und Spannungsführung sowie zunehmend adaptive Betriebsstrategien, die auf probabilistischen Prognosen basieren – einschließlich Extremwertbetrachtungen bei Wind und Last. Die Logik dahinter ist systemisch: Je volatil und dezentraler das System wird, desto stärker verschiebt sich der Engpass von „Hardware allein“ zu „Hardware plus digitale Betriebsführung“. Das ist allerdings nicht plug-and-play. Die eigentliche Hürde liegt häufig in Interoperabilität, Kommunikationsinfrastruktur, Datenzugang und einer durchgängigen Plattformlogik, die Messdaten, Topologie, Schutz-/Leittechnikereignisse und Betriebsrestriktionen zusammenführt. Erst dann können datengetriebene Verfahren ihre Wirkung entfalten – etwa indem sie sichere Spielräume identifizieren, die sonst aus Vorsicht ungenutzt bleiben, oder indem sie schrittweise in Richtung autonomer Rekonfiguration und kollaborativen Asset-Managements führen.

Use Case 7: Schalthandlungen und Engpassmanagement

Die Unterstützung von Schalthandlungen und Engpassmanagement gehört zu den sensibelsten KI-Anwendungsfällen überhaupt. Hier treffen physikalische Restriktionen, regulatorische Vorgaben, Sicherheitslogik und Haftungsfragen unmittelbar aufeinander. Der Wert von KI liegt nicht in einer „automatischen Netzführung“ im simplen Sinne, sondern in der Fähigkeit, aus historischen Situationen, aktuellen Zustandsdaten, Lastflussmodellen und Unsicherheitsinformationen schneller belastbare Handlungsoptionen abzuleiten.

Ein technisch sinnvoller Ansatz besteht darin, Prognosen, Zustandsabschätzung und Optimierung zu koppeln. Das Modell muss also sowohl vorhersagen, was wahrscheinlich eintritt, als auch bewerten, welche Handlungsoption unter den gegebenen Restriktionen robust ist. In partiell beobachtbaren Situationen – etwa bei unvollständiger Sensorik, unsicheren Einspeiseverläufen oder unklarer Geräteverfügbarkeit – ist zustandsunsicherheits-basierte Entscheidungsfindung („belief-based decision making“) besonders hilfreich: Das System managt explizit Unsicherheit über den Netzzustand und wählt Aktionen, die robust gegen diese Unsicherheit sind. Die operative Schwelle zur Automatisierung bleibt jedoch hoch. Gerade weil diese Use Cases tief in die Verantwortung der

Betriebsführung eingreifen, sind Nachvollziehbarkeit, Anfechtbarkeit und klare Guardrails wichtiger als maximale algorithmische „Eleganz“. Eine reife Umsetzung trennt Prognose und Optionsbildung von der Autorität, Schaltbefehle auszulösen. KI kann zulässige Handlungswege, Unsicherheit und erwartete Netzwirkung bewerten. Freigegebene Verfahren, Systemführung sowie Schutz und Leittechnik behalten die Autorität für die physische Umsetzung. So kann die Koordinationsreife steigen, während betriebliche Verantwortung eindeutig bleibt.

Use Case 8: Cybersecurity in OT/IT-konvergenten Umgebungen

Mit der Digitalisierung von Windparks, Umspannwerken und konverternaher Infrastruktur entsteht ein immer dichteres Geflecht aus Fernzugriffen, APIs, Datenpipelines, zentralen Analyseplattformen und dezentralen Edge-Komponenten. Diese Vernetzung schafft den Nährboden für produktive KI – und gleichzeitig neue Angriffsflächen. KI im Cyber-Kontext ist deshalb doppelt relevant: Einerseits als Werkzeug zur Erkennung ungewöhnlicher Kommunikations- und Zugriffsmuster, andererseits als Designproblem für sichere Architekturen. Der Nutzen besteht nicht bloß darin, Angriffe zu entdecken, sondern Auffälligkeiten frühzeitig so zu kontextualisieren, dass Betrieb, Security und Asset-Verantwortung gemeinsam handlungsfähig werden.

Gerade in OT-Umgebungen darf Security nicht zu Lasten der Verfügbarkeit gedacht werden. Ein überaggressives Blocking kann selbst zum Betriebsrisiko werden. Deshalb ist auch hier die richtige Balance gefragt: segmentierte Architekturen, saubere Identitäts- und Berechtigungskonzepte, auditierbare Datenflüsse und klar definierte Reaktionspfade. KI ist in diesem Feld kein Ersatz für gute Security-Architektur, sondern ein Verstärker dort, wo Mustererkennung über menschliche Wahrnehmungsgrenzen hinausgeht.

Use Case 9: GenAI für Engineering und Operations

Generative KI hat im Wind- und Netzkontext einen anderen Charakter als klassische ML-Use-Cases. Hier geht es meist nicht um Echtzeitentscheidungen im technischen Prozess, sondern um die Produktivität wissensintensiver Arbeit. Engineering-Dokumente, Betriebshandbücher, Wartungsberichte, Lessons Learned, Alarmtexte, Spezifikationen und Freigabedokumente bilden in vielen Organisationen einen schwer zugänglichen Wissensraum. GenAI kann diesen Raum erschließen, indem Informationen schneller auffindbar, zusammenfassbar und in Handlungskontexte übersetzbar werden. Der eigentliche Mehrwert liegt in der Beschleunigung qualifizierter Wissensarbeit, nicht in der freien Textproduktion.

Damit GenAI in diesem Umfeld tragfähig wird, muss jedoch die Provenienz der Antworten gesichert sein. Im industriellen Betrieb genügt eine sprachlich plausible Antwort nicht; jede Empfehlung, Zusammenfassung oder Analyse muss auf belastbare Quellen zurückführbar sein. Retrieval-augmented Generation, rollenbasierte Zugriffe, vertrauliche Betriebsumgebungen und Logging sind daher zentrale Voraussetzungen. GenAI ist dort besonders stark, wo es Menschen bei Standardisierung, Voranalyse, Dokumentation und Wissenszugang unterstützt. Es ist dort schwach, wo Quellenlage, Haftung oder technische Konsequenz eine ungesicherte Halluzination untragbar machen würden.

Ein besonders praxisnaher GenAI-Anwendungsfall im Energiesektor ist nicht die freie Textproduktion, sondern die Interaktionsschicht zu Modellen: GenAI als „Energy-Modelling-Copilot“. In Planungs- und Transformationsprojekten arbeiten Teams mit komplexen Simulations- und Optimierungsg-

umgebungen, häufig über Monate, mit unvollständigen Daten und vielen Stakeholdern. Hier kann eine konversationelle Schnittstelle, die Modellkonfiguration, Datenverständnis, Szenariodesign und Ergebnisinterpretation unterstützt, die Produktivität erheblich steigern, vor allem, weil sie den Zugang zu Modellierungsarbeit für ein breiteres Spektrum qualifizierter Nutzer:innen öffnet. Entscheidend ist dabei die klare Abgrenzung: Solche Copilots sind primär für Planung, Szenarien und „What-if“-Analysen gedacht, nicht als Echtzeit-Autopilot für die Betriebsführung. Gerade bei „imperfect data“ kann GenAI helfen, Lücken sichtbar zu machen, Annahmen transparent zu dokumentieren und plausible Optionen zu strukturieren, sofern Provenienz, Unsicherheitskennzeichnung und Validierungslogik konsequent umgesetzt sind. Technisch ist dies ein idealer Brückenschlag zwischen Digital Twin, Optimierung und Wissensarbeit: Der Copilot verbindet Datenräume, Modellbibliotheken und Dokumentation, ohne selbst zum Entscheider zu werden. Erhält ein solcher Copilot zusätzlich Zugriff auf Engineering Werkzeuge oder Workflow Systeme, muss die Betriebslogik festlegen, welcher Kontext abgerufen werden darf, welche Aktionen vorbereitet werden können, welche Werkzeuge aufgerufen werden dürfen und an welchen Stellen eine menschliche Freigabe erforderlich bleibt.

LLM-basierte Systeme unterscheiden sich betrieblich von klassischen Softwarekomponenten: Sie sind nichtdeterministisch, ihre Eingaben sind praktisch unbegrenzt variabel, und ihr Fehlverhalten zeigt sich selten als klarer „Crash“, sondern als Qualitätsdrift, unerwartete Halluzinationen, Parsing-Fehler oder schleichend steigende Latenz. Deshalb ist Observability für LLM-Systeme keine Kür, sondern die Voraussetzung für stabile Nutzung. Ein produktionsfähiger Ansatz beginnt mit Telemetrie über Inputs, Outputs, Fehlerklassen, Parsing-Ergebnisse, Tool-Calls und Nutzerfeedback, und führt diese Signale in eine Betriebslogik über, die messbare *Service-Level-Objectives* (SLOs) definiert. In vielen Fällen sind zwei SLO-Klassen ein pragmatischer Start: (i) *Latenz* (p95/p99) und (ii) Fehlerraten bzw. „task success rates“, ergänzt um Qualitäts-Proxies (z. B. Zitierquote aus Quellen, Anteil verweigerter Antworten bei fehlender Evidenz). Besonders relevant wird dies, wenn GenAI in agentischen Workflows Kontext abrufen, Werkzeuge aufrufen, Maßnahmen vorbereitet oder Aufgaben koordiniert. Jeder Workflow benötigt dann explizite Werkzeugberechtigungen, Aktionsgrenzen, Freigabepunkte, Logging und einen definierten Fallbackpfad.

7. Battery Energy Storage Systems (BESS) als Brücke zwischen Windenergie, Netzbetrieb und Märkten

BESS erweitert die Wind-/Netz-Perspektive um ein Element, das im Energiesystem eine besondere Eigenschaft besitzt: Es kann Leistung in beide Richtungen bereitstellen (laden/entladen), es kann dies sehr schnell tun, und es kann, je nach Auslegung und Regelung, sowohl energiewirtschaftliche als auch netztechnische Funktionen übernehmen. Damit wird BESS zum „Kopplungsglied“ zwischen drei Logiken, die im Betrieb häufig getrennt behandelt werden: (i) *Erzeugungsvolatilität* (Wind), (ii) *Netzbetriebsrestriktionen* (Engpässe, Spannung, Systemstärke), (iii) *Marktlogik* (Arbitrage, Regelernergie, Kapazität, Verträge). Genau diese Kopplung macht BESS KI- und ML-intensiv. Nicht weil die Mathematik neu wäre, sondern weil sich mehrere Zielsysteme gleichzeitig und dynamisch überlagern.

Die Batterie liefert damit ein kompaktes Beispiel für die Verbindung von Intelligenz, Autorität und Asset Ökonomie. Jede Dispatchentscheidung verändert gleichzeitig Marktwert,

Netzwerk, thermische Belastung und Lebensdauerverbrauch. Das Betriebsmodell muss diese Folgen zusammenführen, damit lokale Optimierung Kosten oder Risiken nicht in andere Teile des Assets oder Systems verlagert.

8. BESS-Use Cases: Warum KI/ML hier besonders „natürlich“ ist

(a) Erneuerbaren-Integration, Smoothing und Firing („Wind glätten“ am Netzanschlusspunkt)

Für Windparks bedeutet BESS operativ: Fluktuationen am Point of Common Coupling (PCC) werden geglättet, Rampen reduziert, Prognosefehler abgefedert, und in bestimmten Konstellationen kann die Einspeisung zeitlich verschoben werden („firing“). Diese Funktion gewinnt systemisch an Bedeutung, weil künftige Netze stärker dezentral, volatil und dynamischer werden – Hybrid Energy Storage (HES) adressiert dabei explizit das Problem, dass einzelne Speichertechnologien nicht über alle Zeitskalen optimal sind, und diskutiert Sizing und Power-Management-Strategien zur Maximierung der Glättungswirkung.

KI/ML kommt hier dort ins Spiel, wo das Steuerproblem nicht deterministisch ist: Wind- und Lastregime wechseln, Prognosen haben Unsicherheiten, der Speicher hat SOC- und Leistungsgrenzen, und die optimale Fahrweise hängt von einem Zielmix aus Glättung, Kosten, Degradation und Markterlösen ab.

(b) Systemdienste: Frequenz-, Spannungs- und Inertial Services bis hin zu Schwarzstart

Im Netzbetrieb wird BESS zunehmend als Systemdienstleister relevant. Die Kurzstudie zur Systemdienlichkeit von Großbatterien benennt explizit: Momentanreserve (als unverzögerte Reaktion auf Leistungsungleichgewichte), historisch durch rotierende Massen bereitgestellt, künftig zunehmend durch umrichterbasierte Anlagen; und sie weist darauf hin, dass Batterien dies grundsätzlich leisten können, dann aber netzbildende Wechselrichter benötigen. Außerdem wird Schwarzstartfähigkeit als Rolle von Großbatterien beschrieben, besonders relevant in Regionen ohne geeignete konventionelle Kraftwerke.

Aus ML und KI Sicht verbinden diese Systemdienste Zustandsbewertung, Prognose und übergeordnete Optimierung mit deterministischen Regelungsfunktionen. KI kann Zustandsbewertung, Auswahl von Betriebspunkten, Constraint Monitoring und Nachweisführung unterstützen. Frequenz und Spannungsstützung beruhen auf schnellen Inverter, Schutz und Regelungsfunktionen innerhalb validierter technischer Grenzen. Schwarzstart erfordert darüber hinaus robuste Sequenzen, explizite Autorität und belastbare operative Nachweise.

(c) Engpass- und Redispatch-Wirkung („Netzdienlichkeit“ statt nur Marktdienlichkeit)

Die Systemdienlichkeitsstudie betont sehr klar, dass Batterien in Deutschland derzeit überwiegend marktbasiert betrieben werden und dass das Potenzial zur Senkung von Netzkosten (insbesondere über Engpassreduktion und damit Redispatch) nicht systematisch ausgeschöpft wird, u. a. wegen fehlender Anreize in der einheitlichen Preiszone. Zugleich werden externe Effekte benannt: Wirkung auf Redispatch, kurzfristige Einsatzänderungen auf Engpässe, Fehlanreize innerhalb der 15-min-Bilanzierungsperiode, Fahrplansprünge zwischen MTUs, Einfluss auf Spannungshaltung.

Damit ist die Problemstellung für KI/Optimierung praktisch perfekt beschrieben: Es handelt sich um ein mehrzieliges,

restriktionsbehaftetes, zeitdiskretes Entscheidungsproblem, bei dem eine rein marktgetriebene Zielfunktion (Arbitrage/Regelenergie) zu systemisch ungünstigen Netzzoutcomes führen kann. Die Studie zeigt zudem Instrumenten-klassen, die genau diese Dimension adressieren (regionalisierte Signale, Netzanschluss-Leitplanken, Rampen-begrenzungen, frühere Gate Closure etc.).

(d) Revenue-/Value-Stacking als Betriebsrealität

Sobald BESS im System steht, wird es wirtschaftlich typischerweise nicht über einen Use Case geführt, sondern über Value Stacking: Arbitrage + Frequenzdienst + Engpass-/Netzdienst + ggf. Kapazität/Verträge. *Schmidt & Staffell* beschreiben „Revenue Stacking“ als strukturelles Wertprinzip und geben eine systematische Landkarte der Anwendungen (u. a. Frequency response/regulation, voltage support, black start, congestion relief, T&D deferral, renewables firming/smoothing, arbitrage).

Alexa Capital argumentiert aus Investorensicht ähnlich: heutige Returns basieren häufig auf einem diversifizierten Value Stack (Arbitrage + grid/utility services + ggf. Kapazitätzahlungen), während reine Arbitrage in vielen Märkten allein oft nicht stabil genug ist. Technisch heißt das: Die Fahrweise muss nicht nur „physikalisch möglich“, sondern auch markt-, netz- und garantie- bzw. degradationskompatibel sein, ein idealer Nährboden für datengetriebene Dispatch- und Policy-Optimierung.

9. Wo genau sitzen die KI-/ML-Algorithmen im BESS-Stack?

BESS ist besonders interessant, weil es den klassischen Dreiklang „Schätzen - Prognostizieren - Entscheiden“ in konzentrierter Form enthält. Diese drei Ebenen sind gemeinsam mit dem Autoritätsmodell aus Kapitel 3 zu lesen: Schätzen und Prognostizieren erzeugen Entscheidungsevidenz, Dispatch bereitet zulässige Handlungsoptionen vor oder wählt sie aus, und die physische Ausführung bleibt durch die jeweilige Betriebs- und Regelungsarchitektur begrenzt.

(i) State Estimation: SOC/SOH als Hidden-State-Problem (partiell beobachtbar)

Der wichtigste operative *Zustand* eines Batteriesystems, *State of Charge* (SOC) und *State of Health* (SOH), ist nicht direkt messbar, sondern muss aus Strömen, Spannungen, Temperaturen, Impedanz-/OCV-Charakteristik, Zellbalancing-Informationen und Betriebsverlauf geschätzt werden. Mathematisch ist das ein typisches Hidden-State-Problem: ein (nichtlinearer) Zustand x_t (SOC, interne Parameter) entwickelt sich über ein Dynamikmodell, und Messungen y_t (V, I, T, ggf. impedance proxies) liefern nur indirekte Information. In der Praxis werden dafür Filterfamilien (Kalman-Varianten/Partikel) und zunehmend ML-basierte Surrogates kombiniert; wichtig ist: Modell- und Messfehler sind nicht konstant, sondern abhängig von Temperatur, C-Rate, Alterung und Betriebsmodus.

Welche Daten müssen vorliegen? Hochauflösende Zeitreihen von I/V/T (idealerweise auf String-/ Zellebene oder mindestens Rackebene), Betriebsmodi, BMS-Logs (Balancing, Limits, Alarmer), Umgebung/Containerklima, sowie Ereignisdaten (Trips, Limit-Hits, Firmwareänderungen). Ohne diese Granularität bleibt SOC/SOH eine Schätzung „im Nebel“, und alle nachgelagerten ML-/ Optimierungsentscheidungen werden zwangsläufig instabil.

Typische IT-/Prozessschwierigkeit: In vielen Projekten sind BMS-Daten und EMS/SCADA-Daten nicht vollständig integriert (Zeitstempeldrift, unterschiedliche Samplingraten, fehlende

Historisierung). Ergebnis: Man kann zwar im Nachhinein Reports erzeugen, aber nicht zuverlässig in Echtzeit steuern – und man kann Degradation nicht sauber attribuieren (war es Temperatur, C-Rate, ein bestimmter Market-Dispatch, oder ein BMS-Limit?).

(ii) Degradation- und Lifetime-Modelle: RUL als ökonomisch-technische Nebenbedingung

Die zweite algorithmische Kernschicht ist *Degradation*: Die optimale Fahrweise eines BESS ist nicht nur eine Frage von Preisen/Netz, sondern auch eine Frage von Lebensdauerkosten und Garantiebedingungen. Operativ bedeutet das: Jede Fahrweise ist ein Trade-off zwischen kurzfristigem Nutzen (Erlöse/Systemdienst) und langfristigem Asset-Verbrauch (Kapazitätsfode, Widerstandszunahme, erhöhte Ausfallwahrscheinlichkeit, Warranty-Risiko). Das ist strukturell identisch zu „Predictive Maintenance“ in Wind – nur dass bei BESS Degradation stärker fahrweisen-getrieben und damit direkt optimierbar ist.

Welche Daten müssen vorliegen? Cycle-Counting (Äquivalenzzyklen), Depth of Discharge, C-Rate-Profil, Temperaturprofile, Zeit in hohen SOC-Bereichen, Ereignisse (Overtemp, Overvoltage), Wartung/ Teiltasch. Dazu kommt: Man braucht eine stabile Zuordnung zwischen „Einsatzprofil“ und „zustandsbezogenem Outcome“ (SOH, Kapazität, Innenwiderstand).

Typische IT-/Prozessschwierigkeit: Wenn Markt-/ Netzdiasch und BMS-Daten getrennt laufen, entsteht eine Governance-Lücke: Die Organisation optimiert dann z. B. auf Erlöse und stellt erst später fest, dass sie gegen Degradation-/ Warranty-Constraints „optimiert“ hat. Das ist die Proxy-Falle in Reinform, nur dass sie hier direkt monetär wird.

(iii) Dispatch und Optimierung: Multi-Objective, stochastic, constraint-heavy

Die dritte Schicht ist die eigentliche *Entscheidung*: Wann laden, wann entladen, wann Reserve halten, welche Rampen fahren, welche SOC-Targets setzen, wie auf Netzrestriktionen reagieren. Das ist konzeptionell sehr nah an den MIQP/MICQP-basierten Konstrukten der Betreiber von Energiehandel-Spotmärkten: Nebenbedingungen (SOC-Dynamik, Leistungsgrenzen, Effizienz, Rampen, Netzlimits, Marktprodukte) plus Zielfunktion (Revenue Stack, Netzdienstlichkeit, Degradationkosten, Risiko). Der Unterschied ist nicht die Mathematik an sich, sondern der Grad an Unsicherheit und nicht-stationären Randbedingungen: Preise und Engpasszustände sind stochastisch, Forecasts fehlerbehaftet, Netzrestriktionen können kurzfristig entstehen. In dieser Schicht ist ML/KI besonders wirksam als (a) probabilistischer Forecaster (Preise, Engpassindikatoren, Wind/Last), (b) Surrogate für schnelle What-if-Evaluation, (c) Policy-Learning (nur mit Guardrails), sowie (d) Anomalie-bzw. Constraint-Detection (um gefährliche Fahrweisen früh zu erkennen).

10. Konkrete BESS-Anwendungsbeispiele

BESS-Use Case 1: Wind-PCC-Smoothing und Rampen-management (mit HESS-Option)

In Windparks oder Wind-Clustersituationen kann ein BESS gezielt so gesteuert werden, dass die Einspeisung am PCC „ruhiger“ wird: kurzfristige Fluktuationen (Sekunden/Minuten) werden gedämpft, Rampen begrenzt, und ggf. wird Energie verschoben, um prognostizierte Einspeiseprofile zu glätten. Der HESS-Ansatz ist hier besonders interessant, weil er ausdrücklich die Mehrzeitskalen-Fähigkeit adressiert: unterschiedliche

Speichertechnologien ergänzen sich, um sowohl schnelle als auch langsamere Variabilität abzudecken, und die Power-Management-Strategie wird zum zentralen Optimierungsproblem.

Daten: SCADA/Wind/NWP-Ensembles, PCC-Messungen (P/Q), BESS I/V/T/SOC, Netzrestriktionen (Rampenlimits, Blindleistungsanforderungen).

Schwierigkeit bei schwacher IT/Prozesslage: Wenn PCC-Messwerte und BESS-Steuerung nicht echtzeitnah gekoppelt sind (Latenz, Zeitstempel), entsteht ein „regelungstechnisches“ Problem: Das BESS reagiert zu spät oder auf falsche Signale, was die Stabilität verschlechtert, statt verbessert.

BESS-Use Case 2: Netzdienliche Engpassführung / Redispatch-Entlastung (co-optimized)

Die Systemdienlichkeitsstudie macht deutlich: Der größte netzseitige Hebel liegt potenziell in der Reduktion von Engpässen (Redispatchkosten, Netzausbau), aber das passiert heute nicht systematisch.

Ein engineering-ready Use Case wäre daher eine co-optimierte Betriebsstrategie, die Markt- und Netzsignale integriert: BESS lädt nicht nur bei niedrigem Preis, sondern auch dann, wenn es netzseitig entlastet (oder entlädt nicht, wenn es Engpässe verschärft). Gleichzeitig müssen kurzfristige Einsatzänderungen kontrolliert werden, weil sie selbst Engpässe auslösen können.

Daten: Engpassindikatoren (z. B. PTDF-basierte Sensitivitäten, TSO/DSO-Redispatch-Signale), Netzzustand/Topologie, Market Price Curves, BESS-Betriebsdaten, Gate Closure/MTU-Logik.

Schwierigkeit: Ohne klare Regelung/Instrumente (regionale Signale, Leitplanken, Rampenbegrenzung) bleibt das Problem strukturell ungelöst; die Studie listet genau solche Instrumentenfamilien.

BESS-Use Case 3: Systemdienste – Momentanreserve, Frequenzstützung, Spannungshaltung, Schwarzstart

Mit sinkender rotierender Masse werden inverterbasierte Beiträge wichtiger. Die (Systemdienlichkeits-)Studie benennt explizit Momentanreserve ab 2026 mit Vergütung durch die deutschen ÜNB (~50-70 €/MW·h, erste Ausschreibungen Q1/2026) und die Notwendigkeit netzbildender Wechselrichter, sowie Schwarzstartpotenzial.

KI und ML tragen hier primär zu Zustandsbewertung, Prognose, übergeordneter Optimierung und Monitoring bei. Netzbildende Inverterfunktionen, Schutz und schnelle Regelkreise bleiben deterministisch und zertifiziert. Der Safety Case hängt von der kontrollierten Schnittstelle zwischen diesen Ebenen ab.

Daten: Hochfrequente Messungen (Frequenz, df/dt , Spannungen, Phasenwinkel, P/Q), BESS-Inverterdaten, Schutz-/Leittechnik-Events, Synchronisationsqualität.

Schwierigkeit: In vielen Organisationen sind Schutz- und Leittechnikdaten, BESS-EMS und Markt-/ Dispatchsysteme organisatorisch getrennt. Das führt zu „Zuständigkeitsbrüchen“ und erschwert Auditierbarkeit und Störungsanalyse.

BESS-Use Case 4: Revenue Stacking als Optimierungsproblem (marktlich + technisch + regulatorisch)

Schmidt/Staffell liefern die Landkarte der Anwendungen und das Prinzip, dass Speicher durch gleichzeitiges Bedienen mehrerer Services Wert maximieren („revenue stacking“).

Alexa Capital beschreibt aus Investorensicht, dass große Batterien heute häufig gerade deshalb attraktiv werden, weil Erlöse aus Arbitrage mit weiteren Services kombiniert werden,

und nennt dabei explizit frequency regulation, congestion relief und andere ancillary services als Teil des Stacks.

Engineering-ready bedeutet hier: Betreiber brauchen eine Fahrweise, die SOC-Verfügbarkeit für mehrere Märkte gleichzeitig managt (z. B. Reserve halten vs. Arbitrage fahren), und dabei Degradation/Warranty einpreist.

Daten: Preiszeitreihen (DA/ID), Produktdefinitionen (Regelenergie), Aktivierungen, Netzsignale, BESS-Constraints, Warranty/ Degradation-Kostenmodelle.

Schwierigkeit: Wenn die IT-Landschaft keine konsistente „Single Schedule Source“ und keine SOC-/ Constraint-Transparenz bietet, entstehen interne Konflikte (Trading vs. Ops vs. Asset Health), die praktisch jede ML-gestützte Optimierung aushebeln. Für Investitionsentscheidungen und operative Governance ist deshalb der Nettosystemwert nach Degradation, Reserveverpflichtungen, Netzrestriktionen, Bilanzkreisrisiken und Betriebskosten die relevante Messgröße. Ein reiner Erlösblick kann die Qualität der Dispatchstrategie überschätzen.

11. Schlussbemerkung

Die Einführung von KI in Windenergie und Netzbetrieb ist Teil einer tieferen Transformation technischer Betriebsführung. Reaktive, fragmentierte und implizite Entscheidungslogik entwickelt sich zu einer expliziteren, datenbasierten, probabilistischen und auditierbaren Form des Handelns. Organisatorische Reife zeigt sich in der Fähigkeit, Modelle, Prozesse, Menschen, Sicherheitslogik und Governance in eine tragfähige operative Architektur zu überführen.

Über den Lebenszyklus hinweg definiert Plan das System und seine Wertlogik. **Design** legt Evidenz, Entscheidungspfade und Autoritätsgrenzen fest. **Build** integriert Modelle, Workflows, Werkzeuge und Controls und testet Verhalten unter normalen und degradierten Bedingungen. **Operate** verbindet Runtime Monitoring, Revalidierung, Value Attribution und strukturiertes Lernen. Daraus entsteht ein geschlossener Kreislauf von Wahrnehmung und Vorausschau über koordinierte Handlung bis zur gemessenen Konsequenz. Die dauerhafte Fähigkeit liegt in einer Betriebsdisziplin, die analytische Tiefe und delegierte Handlung erweitern kann und zugleich verantwortetes menschliches Urteil, deterministischen Schutz und Wiederherstellungsfähigkeit unter degradierten Bedingungen erhält.

Annex I - Definitionen

1) Lineare Regression (Prognose / Regressionsbasis)

Mathematische Definition

Gegeben Trainingsdaten (x_i, y_i) mit $x_i \in \mathbb{R}^d, y_i \in \mathbb{R}$. Lineare Regression sucht Parameter $\beta \in \mathbb{R}^d$ (und optional Interzept b), die den quadratischen Fehler minimieren: $\min_{\beta, b} \sum_{i=1}^n (y_i - (\beta^\top x_i + b))^2$.

Praktisches Beispiel (Wind/Netz)

- **Wind**: Kurzfristiger Zusammenhang zwischen Windgeschwindigkeit (oder NWP-Features) und Leistung – als Baseline oder als Feature in komplexeren Modellen
- **Netz**: Zusammenhang zwischen Last $L(t)$ und Preis/Engpassindikatoren, z.B. mittels Regressionen und anhand Illustration von Strompreis vs. Last

Welche Daten müssen vorliegen?

Zeitlich synchronisierte Feature-Vektoren (SCADA/NWP/Lastfluss) + Zielgröße (Leistung, Last, Engpasskosten, etc.).
Wichtig: einheitliche Zeitscheiben und saubere Flags (Curtailment, Ausfälle), sonst "lernt" das Modell Betriebsstörungen als Physik.

Typische Schwierigkeiten bei schwacher IT/Prozesslandschaft

- Manuelle Datenzusammenführung (Excel-ETL) → inkonsistente Zeitstempel, verlorene Werte, duplizierte Zeilen
- Fehlende Datenqualitätsmetriken (Vollständigkeit, Aktualität, Konsistenz) → Regression wirkt "plausibel", ist aber systematisch verzerrt. Klassischen Datenqualitätsdimensionen und einfache Kennzahlen (z.B. Vollständigkeit als Quotient) sollten explizit aufgeführt sein
- "Proxy-Fälle": Man optimiert z.B. MAPE statt tatsächlicher Systemkosten (asymmetrische Kosten von Forecast-Fehlern)

2) Logistische Regression (Klassifikation von Ereignissen, z. B. Ausfall ja/nein)

Mathematische Definition

Für binäre Labels $y_i \in \{0,1\}$ wird die Wahrscheinlichkeit modelliert als $p(y = 1|x) = \sigma(\beta^\top x + b)$, $\sigma(z) = \frac{1}{1+e^{-z}}$.

Trainiert wird durch Maximum-Likelihood bzw. Minimierung der Kreuzentropie.

Praktisches Beispiel

- **Wind**: "Wird innerhalb der nächsten 7 Tage ein Pitch-Fehler auftreten?" (binary event in einem definierten Vorwarnfenster)
- **Netz**: "Wird ein Alarmcluster zu einem Incident eskalieren?" (OT/IT-Events → Incident-Label)

Datenbedarf

Ereignislabels plus Feature-Vektoren, idealerweise inklusive Kontext (Wetter, Betriebsmodus, Wartung, Firmwarestand).

Prozess-/IT-Probleme

- Labels sind oft nicht sauber (Tiketttexte statt strukturierter Fehlercodes)
- Systembrüche zwischen SCADA, CMMS, Ticketing → du bekommst keinen konsistenten "Ground Truth"

3) Entscheidungsbäume / Random Forests (nichtlineare Modelle, robust gegen Mischdaten)

Mathematische Idee

Ein Entscheidungsbaum approximiert $f(x)$ durch rekursive Partitionierung des Feature-Raums. In der Klassifikation wird häufig die Impurity (Gini/Entropy) minimiert. Ein Random Forest mittelt viele Bäume:

$\hat{f}(x) = \frac{1}{T} \sum_{t=1}^T f_t(x)$, wobei f_t auf Bootstrapsamples und zufälligen Feature-Subsets trainiert wird.

Praktisches Beispiel

- **Wind**: Fehlerklassifikation (Umrichter/Pitch/Generator) aus SCADA- und CMS-Features
- **Netz**: Priorisierung von Alarmen aus Leittechnik + Telemetrie

Datenbedarf

Gemischte strukturierte Daten sind ok (numerisch + kategorisch). Random Forests sind oft "dankbar", wenn Feature Engineering solide ist.

Schwierigkeiten bei ungenügender IT/Prozesslage

- Ohne Feature-Store/Versionierung: identische Features werden in verschiedenen Teams unterschiedlich berechnet → Modelle sind nicht reproduzierbar
- Schema-Änderungen (neue SCADA-Spalten, neue Alarmcodes) brechen Pipelines und sollten als Data-Quality/Observability-Thema adressiert sein

4) Support Vector Machines (SVM) – Trennflächen / Margin-Maximierung

Mathematische Definition (linear)

Für Labels $y_i \in \{-1, +1\}$: $\min_{w,b} \frac{1}{2} |w|^2 \quad \text{s.t.} \quad y_i(w^\top x_i + b) \geq 1$.

Mit Soft Margin kommen Slack-Variablen und ein Strafparameter C dazu. Mit Kernel-Trick kann man nichtlinear trennen.

Praktisches Beispiel

- **Wind**: Klassifikation “normal vs. anomal” im Feature-Raum (z. B. Spektralfeatures)
- **Netz**: Klassifikation von Betriebssituationen (z. B. “stable vs. critical”)

Datenbedarf / Stolpersteine

- SVM skaliert schlechter bei sehr großen Datenmengen; braucht saubere Feature-Skalierung
- In OT/SCADA-Welten sind Features oft nicht normalisiert und nicht konsistent → “einmal gut, später drift”

5) Bayessche Inferenz (Bayesian Models) – Unsicherheit explizit im Modell

Mathematische Definition

Man modelliert Parameter θ probabilistisch und aktualisiert per Bayes: $p(\theta|D) = \frac{p(D|\theta)p(\theta)}{p(D)}$.

Praktisches Beispiel

- **Wind-Forecasting**: probabilistische Prognosen (Konfidenzintervalle), Regimewechsel (Saisonalität, Wake)
- **Netz**: Zustands-/Risikoschätzung unter unsicheren Messungen

Datenanforderung

Nicht zwingend “mehr Daten”, sondern saubere Likelihood-/Fehlerannahmen und konsistente Messketten.

IT/Prozess-Schwächen

Bayes-Modelle sind empfindlich auf “stillen Datenbruch”: Wenn sich Messdefinitionen ändern (Sensor-Tausch, Kalibrierung), passt die Likelihood nicht mehr → Posterior wird falsch

6) k-means Clustering (Unsupervised) – Zustands-/Betriebsregime finden

Mathematische Definition

Für k Clusterzentren μ_j : $\min_{\{\mu_j\}} \sum_{i=1}^n \min_{1 \leq j \leq k} |x_i - \mu_j|^2$.

Praktisches Beispiel

- **Wind**: Betriebsregime clustern (z. B. “normaler Betrieb”, “Curtailement”, “icing-like patterns”)
- **Netz**: Muster von Ereignis- und Lastflusszuständen

Datenbedarf

Feature-Vektoren, sinnvoll normalisiert; robuste Features (sonst clustert man nur Sensorartefakte).

Schwierigkeiten ohne gute IT/Prozesse

- “Garbage in, garbage out”: Wenn Datenqualität schwankt, liefert k-means scheinbar plausible Cluster, die in Wahrheit ETL-/Sensorprobleme reflektieren
- Ohne Data Lineage/Audit ist die Ursachenanalyse fast unmöglich – **note**: wichtig sind Lineage/Audit Trails und Observability für Reproduzierbarkeit und Debugging

7) PCA (Principal Component Analysis) – Dimensionsreduktion / Feature-Kompaktierung

Mathematische Definition

PCA sucht orthonormale Richtungen $w_1, \dots, w_m$, die die Varianz maximieren. Äquivalent: Eigenvektoren der Kovarianzmatrix Σ zu den größten Eigenwerten:

$$\Sigma w = \lambda w.$$

Praktisches Beispiel

- **Wind/CMS**: Spektraldaten stark verdichten; Hauptkomponenten als Input für Anomalie-/RUL-Modelle.
- **Netz**: viele korrelierte Messgrößen (Spannungen/Ströme/Phasen) zu wenigen stabilen Faktoren reduzieren.

Datenbedarf

Kontinuierliche, skaliert/zentrierte Daten; PCA ist sensitiv gegenüber Ausreißern.

IT/Prozess-Probleme

Wenn Daten “stale” sind oder Zeitsynchronität fehlt, kann PCA falsche Dominanzen lernen. In meiner Toolbox werden für Control-Center-Prozesse u. a. Data Freshness, Availability und Query Latency als systemische Anforderungen beschrieben – genau das ist die Grundlage, damit PCA & Co. überhaupt sinnvoll sind.

8) Neuronale Netze / Deep Learning (inkl. Backpropagation) – universelle Funktionsapproximation

Mathematische Grundform

Ein Feedforward-Netz ist eine Komposition $f(x; W) = \phi_L(W_L \phi_{L-1}(\dots \phi_1(W_1 x)))$. Trainiert wird typischerweise durch Gradientenabstieg auf Loss $L: W \leftarrow W - \eta \nabla_W \sum_i \mathcal{L}(f(x_i; W), y_i)$.

Praktische Beispiele

- CNNs für Rotorblattbilder (Segmentierung/Detektion)
- RNN/LSTM/Transformer für Zeitreihen (Windleistung, Condition Monitoring, Netztelemetrie)
- Autoencoder (siehe nächster Punkt) für Anomalien

Datenbedarf

Viel, konsistent, repräsentativ. Bei Vision: saubere Labels/Annotationen; bei Zeitreihen: stabile Sampling-Raten und klare Maskierung fehlender Werte.

Hauptprobleme bei schwacher IT/Prozesslandschaft

- Trainingsdaten “wandern” (kein Versioning, keine Lineage) → Ergebnisse nicht reproduzierbar
- Bandbreite/Storage/Compute werden zu Engpässen; Reddi beschreibt sehr konkret, dass bei ML Datenbewegung und Infrastruktur schnell “gleich teuer” werden wie das Training selbst und Governance über Observability (Lineage, Audit, Access Control) eine tragende Säule ist
- Ohne konsequente MLOps-Pipeline wird DL im Betrieb schnell zum Vertrauensverlust (“hat gestern gut funktioniert”)

9) Autoencoder / Anomalieerkennung (Unsupervised/Semi-supervised)

Mathematische Idee

Ein Autoencoder lernt Encoder $z = g_\phi(x)$ und Decoder $\hat{x} = h_\theta(z)$, minimiert Rekonstruktionsfehler:

$$\min_{\phi, \theta} \sum_i |x_i - h_\theta(g_\phi(x_i))|^2.$$

Anomalien zeigen sich häufig als hoher Rekonstruktionsfehler oder als Outlier im Latent Space.

Praktisches Beispiel

- **Wind**: Früherkennung ungewöhnlicher CMS-Signaturen, ohne dass viele “failure labels” existieren
- **Netz/OT**: Kommunikations- oder Messmuster, die von Normalprofilen abweichen

Datenbedarf

Viel “Normalbetrieb” (sauber!), und zwar in hinreichender Vielfalt (verschiedene Wetter-/Last-/Betriebsmodi).

IT/Prozess-Fallen

- Wenn “Normaldaten” bereits Curtailment/Fehlkonfiguration enthalten, lernt der Autoencoder genau das als normal. BDEW weist auf datengetriebene Bias-/Fehlrealitäten als generelles KI-Risiko hin
- Ohne Prozessklarheit: Was ist überhaupt “normal” (Betriebsmodi, Wartungsfenster, Firmwarestände)?

10) Gaussian Processes (GP) & Bayesian Optimization / Safe Optimization (Wake-Steering, Controller-Tuning)

GP-Grundidee

Ein Gaussian Process definiert eine Verteilung über Funktionen $f(x) \sim \mathcal{GP}(m(x), k(x, x'))$. Nach Beobachtungen erhält man Posterior-Mittelwert und -Varianz. (In Kochenderfer steht u. a. die Auswahl des nächsten Punktes über $\arg \min \hat{\mu}(x)$ oder $\arg \max \hat{\sigma}(x)$).

SafeOpt (Kernformeln)

SafeOpt nutzt Confidence Bounds $u_i(x), l_i(x)$ und fordert probabilistische Sicherheit $P(f(x) \leq y_{\max}) \geq P_{\text{safe}}$.

Praktisches Beispiel

Wake-Steering/Reglertuning: Man will AEP erhöhen, aber Lastgrenzen/Schwingungsgrenzen nicht reißen. Safe Optimization ist hier “natürlich”, weil man nicht beliebig explorieren darf.

Datenbedarf

Experiment-/Betriebsdaten mit klarer Zuordnung: Stellgrößen x (Yaw-Offsets, Controller-Parameter), Outcome $f(x)$ (AEP/Loads), plus Kontext (Windrichtung, Turbulenz, Betriebsmodus). Ohne Kontext sind die Daten “nicht identifizierbar”.

IT/Prozess-Schäden

- Fehlende Konsistenz/Verfügbarkeit der Daten im Sekunden-/Minutenbereich (Control Center Anforderungen wie Freshness, Availability) → man kann die Wirkung einzelner Stellgrößen nicht sauber isolieren
- Ohne Change-Management: Operatoren ändern parallel Parameter, CMMS-Workorders beeinflussen Betriebszustände → kausale Attribution bricht

11) Reinforcement Learning (RL): MDP, Q-learning, DQN, PPO (nur mit “Safety Case”)

Mathematische Definition (MDP)

Ein Markov Decision Process ist $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$. Ziel ist eine Policy $\pi(a|s)$, die den erwarteten Return maximiert:

$$\max_{\pi} E[\sum_{t=0}^{\infty} \gamma^t r_t].$$

Q-learning (Kernupdate)

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)].$$

Praktisches Beispiel (wo RL theoretisch passt)

Wake-Steering / MPC-ähnliche Regelungsentscheidungen, Dispatch/Logistik als sequenzielles Entscheidungsproblem.

Aber: In kritischer Infrastruktur ist RL in der Realität meist simulationsgetrieben (Digital Twin) und wird dann als Advisory/Guardrailed Automation eingeführt.

Datenbedarf

Interaktionsdaten oder hochwertige Simulation (Digital Twin), definierte Rewards, klare State-Definitionen.

IT/Prozess-Probleme

- Ohne digitale Repräsentation (Twin) und ohne kontrollierte Change-Prozesse wird RL operativ riskant
- “Reward Hacking” ist die Proxy-Falle in Reinform: optimiert wird eine Zahl, nicht das eigentliche Zielsystem

12) GenAI / RAG (Retrieval-Augmented Generation) - Wissensarbeit mit Provenienz

Technische Definition (RAG)

Statt ein LLM “aus dem Kopf” antworten zu lassen, wird Kontext aus einer Wissensbasis abgerufen. Formal:

1. Embedding-Funktion $e(d) \in R^k$ für Dokumente/Chunks und $e(q)$ für Query
2. Retrieval: wähle Top- K Dokumente über Ähnlichkeit, z. B. Cosine: $\text{sim}(q, d) = \frac{e(q) \cdot e(d)}{|e(q)| |e(d)|}$
3. Generation: LLM erzeugt Antwort konditioniert auf die retrieved Dokumente.

Praktisches Beispiel

Engineering/Operations: “Zeige die relevanten Schritte für eine Umrichter-Fehlerklasse X inkl. Lessons Learned und OEM-Manual-Auszügen”, aber mit Quellen-/Provenienzpflcht.

Datenbedarf

Versionierte Dokumente (Manuals, Standards, As-built, Tickets, Reports) + Berechtigungskonzepte.

IT/Prozess-Probleme

- Ohne IAM/Rollenmodell, Audit-Logging und Datenklassifikation ist GenAI schnell nicht produktionsfähig (Datenschutz, Betriebsgeheimnisse). Reddi betont Governance über Observability: Lineage, Audit Trails und Access Controls als Kern
- Ohne Dokumentenqualität/Single Source of Truth: RAG liefert zwar “belegte” Antworten – aber aus veralteten oder widersprüchlichen Quellen

13) Agentic AI und Governed Autonomy

Definition

Agentic AI bezeichnet eine Betriebsarchitektur, in der KI Fähigkeiten Kontext abrufen, Aufgaben vorbereiten oder koordinieren, freigegebene Werkzeuge nutzen und unter expliziter Autorität mit Workflows interagieren. Der Begriff bezeichnet keine eigenständige algorithmische Klasse. Er verbindet prädiktive, optimierende und generative Fähigkeiten entsprechend ihrer betrieblichen Rolle. Governed Autonomy beschreibt die zulässige Autorität solcher Workflows entlang der Stufen Observe, Advise, Coordinate, Act with Approval und Bounded Execution.

Operative Relevanz

Die zentrale Gestaltungsfrage ist das Verhältnis von Fähigkeit und Autorität. Werkzeugzugriff, Evidenzqualität, Betriebsgrenzen, Freigabepunkte, Eingriffsrechte und Fallback bestimmen, welche Rolle ein Workflow im Betriebsprozess übernehmen darf.

ML, KI und GenAI in On-/Offshore-Windenergie und im zugehörigen Netzbetrieb

Annex II - Acronyme

Acronym	Name	About
AEP	Annual Energy Production	Jahresenergieertrag eines Windparks
AI	Artificial Intelligence	Oberbegriff für intelligente Systeme
ALARP	As Low As Reasonably Practicable	Risiko so niedrig wie vertretbar
ANN	Artificial Neural Network	Neuronales Netz zur Funktionsapproximation
API	Application Programming Interface	Schnittstelle für System-zu-System Integration
AR	Augmented Reality	Assistenz durch Überlagerung digitaler Informationen
BESS	Battery Energy Storage System	Batteriespeicher zur Netz- und Marktdienlichkeit
BMS	Battery Management System	Zellschutz, Balancing, Limits, Diagnose
CMMS	Computerized Maintenance Management System	Wartungsplanung, Workorders, Historie
CMS	Condition Monitoring System	Zustandsüberwachung über Sensorik/Signale
CNN	Convolutional Neural Network	Deep Learning für Bild-/Rasterdaten
CRPS	Continuous Ranked Probability Score	Qualitätsmaß probabilistischer Prognosen
CTA	Call to Action	Handlungsaufforderung (z. B. Link klicken)
DA	Day-Ahead	Marktzeitfenster für Folgetag
DL	Deep Learning	ML mit tiefen neuronalen Netzen
DQN	Deep Q-Network	Q-Learning mit neuronaler Approximation
EMS	Energy Management System	Dispatch/Optimierung auf Anlagen-/Parkebene
ETL	Extract, Transform, Load	Datenpipeline für Integration und Aufbereitung
GenAI	Generative Artificial Intelligence	KI zur Generierung von Text/Bild/Code
GNN	Graph Neural Network	Lernen auf Netzen/Topologien/Graphen
GP	Gaussian Process	Bayessches Surrogatmodell mit Unsicherheit
GPU	Graphics Processing Unit	Hardwarebeschleuniger für ML/GenAI
HESS	Hybrid Energy Storage System	Kombinierte Speicher für mehrere Zeitskalen
HPC	High Performance Computing	Hochleistungsrechnen für Training/Simulation
IAM	Identity and Access Management	Rollen, Rechte, Authentifizierung, Zugriffskontrolle
ID	Intraday	Marktzeitfenster innerhalb des Liefertags
LLM	Large Language Model	Sprachmodell für generative Aufgaben
LLMOps	LLM Operations	Betrieb, Monitoring, Qualitätssicherung von LLMs
LSTM	Long Short-Term Memory	RNN-Variante für Zeitreihen/Sequenzen
MAPE	Mean Absolute Percentage Error	Prozentualer Prognosefehler (Punktwert)
MDP	Markov Decision Process	Formalisierung sequenzieller Entscheidungsprobleme
MICQP	Mixed-Integer Convex Quadratic Program	MIQP mit konvexer Quadratik
MIQP	Mixed-Integer Quadratic Program	Optimierung mit Ganzzahlen und Quadratik
MLOps	Machine Learning Operations	Betrieb, Deployment, Monitoring von ML
MPC	Model Predictive Control	Prädiktive Regelung mit Nebenbedingungen
MTU	Market Time Unit	Zeitscheibe der Markt-/Bilanzierung
N-1	N minus 1	Betriebssicherheit trotz Ausfall eines Elements
NLP	Natural Language Processing	Verarbeitung und Analyse natürlicher Sprache
NWP	Numerical Weather Prediction	numerische Wettervorhersage (Modelldaten)
OCV	Open Circuit Voltage	Leerlaufspannung als SOC-Indikator
OEM	Original Equipment Manufacturer	Hersteller von Originalkomponenten
OT	Operational Technology	Betriebstechnik/Leittechnik, Steuerung, Schutz
PCA	Principal Component Analysis	Dimensionsreduktion über Hauptkomponenten
PCC	Point of Common Coupling	Netzanschlusspunkt einer Anlage/Plattform
PMU	Phasor Measurement Unit	Synchrone Messung von Phasoren (hochfrequent)
POMDP	Partially Observable Markov Decision Process	MDP mit unvollständiger Beobachtung
PPO	Proximal Policy Optimization	Policy-Gradient Verfahren im RL
PTDF	Power Transfer Distribution Factor	Sensitivität von Flüssen auf Transfers
Q-learning	Q-learning	Wertfunktionen lernen durch Bellman-Update
RAG	Retrieval-Augmented Generation	Generieren mit dokumentbasierter Evidenz
RL	Reinforcement Learning	Lernen durch Feedback in Entscheidungsfolgen
RNN	Recurrent Neural Network	Neuronales Netz für Sequenzen
RUL	Remaining Useful Life	Restlebensdauer eines Assets/Subsystems
SCADA	Supervisory Control and Data Acquisition	Leitsystemdaten, Steuerung, Telemetrie
SLO	Service Level Objective	Zielwerte für Betrieb (Latenz/Fehler)
SOC	State of Charge	Ladezustand einer Batterie
SOH	State of Health	Gesundheitszustand/Alterung einer Batterie
SVM	Support Vector Machine	Klassifikation über Margin-Maximierung
UEBA	User and Entity Behavior Analytics	Anomalien in Nutzer-/Systemverhalten

Annex III - Referenzen

Energie, Wind, Netz & KI (Sektor-/Policy-/Industrieberichte)

- BDEW (2024), "KI-Landkarte / KI in der Energiewirtschaft (BDEW KI Launch 2406)", Bundesverband der Energie- und Wasserwirtschaft e.V., Berlin
- dena (2024), "Artificial Intelligence for the Integrated Energy Transition", Deutsche Energie-Agentur (dena), Berlin
- Euroelectric (2024), "Wired for Tomorrow", Accenture plc & Euroelectric aisbl, Dublin & Brussels
- Fraunhofer IESE (2023), "Digitale Ökosysteme in Deutschland", Fraunhofer-Institut für Experimentelles Software Engineering IESE, Kaiserslautern
- International Energy Agency (IEA) (2025), "Energy and AI", IEA, Paris

ML/AI Systems, Governance, Fairness, Trustworthiness

- Barocas, S., Hardt, M., and Narayanan, A. (2023), "Fairness and Machine Learning – Limitations and Opportunities", online book, <https://fairmlbook.org/>
- Mohri, M., Rostamizadeh, A., and Talwalkar, A. (2018), "Foundations of Machine Learning", MIT Press, Cambridge, Massachusetts
- Prince, S.J.D. (2026), "Understanding Deep Learning", MIT Press, Cambridge, Massachusetts
- Reddi, V.J. (2026), "Machine Learning Systems – Principles and Practices of Engineering Artificially Intelligent Systems", (Book manuscript), Harvard University

Optimierung, Decision Making, Sequential Decisions / RL

- Boyd, S., and Vandenberghe, L. (2004), "Convex Optimization", Cambridge University Press, Cambridge
- Kochenderfer, M.J., and Wheeler, T.A. (2025), "Algorithms for Optimization", MIT Press, Cambridge, Massachusetts
- Kochenderfer, M.J., Wheeler, T.A., and Wray, K.H. (2022), "Algorithms for Decision Making", MIT Press, Cambridge, Massachusetts
- Sutton, R.S., and Barto, A.G. (2018), "Reinforcement Learning: An Introduction", MIT Press, Cambridge, Massachusetts

BESS / Speicher, Marktintegration, Netzdienlichkeit

- Alexa Capital (2024/2025), "Investing in Energy Storage"
- Eike, A., Hirth, L., und Maurer, C. (2025), "Systemdienlichkeit von Großbatterien - Kurzstudie", Neon Neue Energieökonomik & consentec
- Schmidt, O., and Staffell, I. (2023), "Monetizing Energy Storage"
- Scipioni, A., et al. (2026), "Hybrid Energy Storage (HESS) – concepts, sizing and control"

Cyber-physische Systeme / OT-Security / Power Systems

- Cao, Y., Li, Y., Liu, J., and Rehtanz, C. (2020), "Cyber-physical Power Systems"
- Ibrahim, A. (2021), "VSCs in HVDC Systems", Springer

Regulation & Standards

- EU AI Act (2024), "Regulation on Artificial Intelligence"
- IEC 62443-3-3 (2013), "Security for Industrial Automation and Control Systems – System Security Requirements"
- NIS2-Richtlinie (2023), "Network and Information Security"